Clustering y Redes Neuronales: Una aplicación para el comercio exterior de Bolivia

Alvaro Chirino Gutierrez[1*], Fabian Barba Uria[2**]

[1]Fundación Aru
[2]Fundación Aru

Resumen

Este estudio presenta un análisis integral del comercio exterior boliviano entre 1992 y 2025, mediante técnicas avanzadas de aprendizaje automático aplicadas a series temporales. Se desarrolla un pipeline reproducible que incluye la extracción, transformación y modelado de datos oficiales de importaciones y exportaciones, a nivel de productos (NANDINA) y actividades económicas (CIIU). Se implementa un clustering no supervisado basado en características temporales para segmentar más de diez mil series de tiempo, identificando patrones relevantes en el comportamiento de sectores y productos. Además, se emplean modelos de pronóstico, incluyendo redes neuronales (NNETAR), para anticipar la evolución del saldo comercial. Los resultados permiten una mejor comprensión dinámica de los flujos comerciales y facilitan la toma de decisiones en política económica. Todo el proceso fue documentado en un repositorio de GitHub, que incluye un dashboard para su ejecución local y la visualización de los resultados, esta metodología automatizada y reproducible contribuye a enriquecer la investigación económica en Bolivia, integrando técnicas de machine learning con análisis empírico del comercio internacional.

Keywords: *Clustering, comercio exterior, redes neuronales, pronóstico, analítica predictiva.*
JEL Classification: *C38, C53, F14.*

1 Motivación

El comercio exterior constituye un pilar esencial para el crecimiento económico y la integración de Bolivia en la economía global, un país que enfrenta un proceso continuo de diversificación productiva y apertura internacional [1–3]. Sin embargo, la estructura histórica del comercio exterior boliviano refleja características típicas de economías dependientes de materias primas: alta concentración de exportaciones en hidrocarburos y minerales, limitada participación en cadenas globales de valor y escasa diversificación productiva [3–6]. Esta concentración genera vulnerabilidades frente a las fluctuaciones de precios internacionales y shocks externos, afectando la estabilidad macroeconómica y dificultando la formulación de políticas de desarrollo sostenibles [7, 8].

A nivel técnico, la disponibilidad y organización de los datos oficiales constituye un desafío adicional. Las bases de datos de exportaciones e importaciones publicadas por el Instituto Nacional de Estadística (INE) presentan formatos dispersos, estructuras variables y carecen de interfaces automatizadas para descarga masiva o consultas reproducibles [9, 10]. Esta situación limita el análisis longitudinal y predictivo de los flujos comerciales, y dificulta la identificación de patrones estructurales que podrían informar políticas públicas y estrategias empresariales [11].

La literatura estructuralista ha subrayado cómo la concentración de exportaciones y la dependencia de materias primas condicionan el crecimiento económico y la resiliencia frente a shocks externos [3, 4, 12]. En Bolivia, esta realidad se traduce en desafíos específicos:

- Limitada diversificación productiva y baja

*Profesional en estadística e investigador de Fundación Aru, los comentarios son bienvenidos a achirino@aru.org.bo
**Asistente de investigación de Fundación Aru

participación en manufacturas y servicios con potencial exportador [5, 6].
- Vulnerabilidad de la balanza comercial frente a fluctuaciones externas y precios internacionales de commodities [7, 13].
- Fragmentación y heterogeneidad de los datos oficiales, que dificultan la aplicación de análisis avanzados y la predicción de tendencias [9, 10].

Estos problemas estructurales se combinan con barreras metodológicas, ya que los enfoques tradicionales —estadísticos o econométricos— presentan limitaciones para capturar relaciones no lineales, interacciones complejas y patrones ocultos en grandes volúmenes de datos. La heterogeneidad de productos, destinos y períodos hace que las metodologías convencionales sean insuficientes para generar información predictiva confiable [11, 14, 15].

El aprendizaje automático (ML) y las técnicas de inteligencia artificial (IA) han surgido como herramientas esenciales para enfrentar estos desafíos analíticos. Estudios recientes demuestran que modelos como redes neuronales, perceptrones multicapa, procesos gaussianos y redes neuronales gráficas (GNNs) permiten capturar dependencias no lineales y relaciones complejas entre variables, superando las limitaciones de los métodos econométricos tradicionales [16–19].

Complementariamente, las técnicas de clustering no supervisado ofrecen mecanismos para organizar y segmentar grandes volúmenes de datos heterogéneos, reducir dimensionalidad y detectar patrones ocultos, mejorando la interpretabilidad y robustez de los análisis posteriores [14, 20, 21].

En América Latina, países como Chile, México y Brasil ya han integrado estas metodologías para optimizar cadenas de suministro, segmentar mercados y anticipar la demanda, generando información estratégica para empresas y gobiernos [22–25]. En contraste, Bolivia mantiene un enfoque limitado, centrado en análisis descriptivos y modelos econométricos convencionales, evidenciando un amplio margen para la adopción de técnicas reproducibles y predictivas [11].

El presente estudio aborda de manera integrada los problemas estructurales y técnicos del comercio exterior boliviano mediante:

- La construcción de un oleoducto automatizado de datos oficiales, que permite la descarga, transformación y almacenamiento reproducible de series históricas de exportaciones e importaciones.
- La aplicación combinada de clustering no supervisado y redes neuronales autorregresivas (NNAR) para capturar relaciones complejas, segmentar productos y sectores, y generar predicciones de flujos comerciales.

Este enfoque permite superar las limitaciones estructurales y metodológicas, ofreciendo evidencia sobre concentración exportadora, patrones de diversificación y potenciales áreas de crecimiento. Además, habilita la formulación de políticas públicas basadas en datos, así como la planificación estratégica del sector privado con información predictiva robusta [26].

Finalmente, la integración de ML y clustering con los datos oficiales contribuye al cumplimiento de los Objetivos de Desarrollo Sostenible (ODS 8, 9 y 16) y se alinea con los lineamientos del Plan de Desarrollo Económico y Social (PDES), promoviendo la diversificación productiva, la industrialización con sustitución de importaciones y la mejora de la competitividad comercial [7, 27, 28].

1.1 Machine Learning: Más Allá de la Minería de Datos

Es importante aclarar que, aunque la minería de datos y el machine learning están estrechamente relacionados, no son conceptos equivalentes ni intercambiables. La *minería de datos* se centra en la exploración, selección y descubrimiento de patrones o relaciones en grandes volúmenes de datos, constituyendo una etapa fundamental dentro del ciclo de análisis de datos. Sin embargo, *machine learning* abarca un proceso mucho más amplio e integral, que incluye la preparación de datos, el diseño y entrenamiento de modelos, la validación, la interpretación y, finalmente, la implementación de *soluciones tecnológicas aplicables* a problemas reales [29, 30].

En este sentido, el *machine learning* utiliza los resultados de la minería de datos como insumo, pero va más allá al construir modelos predictivos o prescriptivos capaces de aprender de la experiencia y adaptarse a nuevas situaciones. Por ejemplo, en el contexto del comercio exterior, las soluciones basadas en machine

learning no solo identifican patrones históricos, sino que permiten automatizar procesos, optimizar la toma de decisiones y generar ventajas competitivas sostenibles [18, 31].

Autores como Velasco Tinoco et al. [31] destacan que el verdadero valor de la inteligencia artificial y el aprendizaje automático radica en su capacidad para transformar los datos en herramientas concretas que impactan la gestión, la logística y la estrategia empresarial. Por ello, el *machine learning* debe entenderse como un enfoque integral que culmina en la entrega de herramientas y plataformas tecnológicas aplicables, y no simplemente como una extensión de la minería de datos.

La siguiente sección revisa evidencia empírica reciente que demuestra cómo estas capacidades del *machine learning* se han aplicado con éxito en el análisis del comercio internacional, superando las limitaciones de los enfoques tradicionales y abriendo nuevas posibilidades metodológicas.

2 Literatura Relevante

La modelización de las exportaciones es una herramienta estratégica esencial para naciones y empresas [32]. A nivel corporativo, su aplicación es vital para desarrollar estrategias efectivas, permitiendo a las organizaciones anticipar tendencias futuras y tomar decisiones informadas. Esto incluye aspectos cruciales como la capacidad de producción, la gestión de inventarios, la expansión de mercados y la fijación de precios [32].

Es común que los términos aprendizaje automático (ML), inteligencia artificial (IA) y aprendizaje profundo (DL) se usen de forma indistinta. Sin embargo, es importante aclarar que el ML es un subcampo de la IA, que a su vez es una disciplina más amplia dentro de la informática. El objetivo principal del ML es que los sistemas aprendan directamente de los datos utilizando métodos estadísticos [33].

El Machine Learning (ML) ha ganado terreno en la economía aplicada gracias a varios factores clave. El aumento masivo de datos y los avances tecnológicos —como las Unidades de Procesamiento Gráfico (GPUs)— han facilitado el procesamiento eficiente de grandes volúmenes de información. Adicionalmente, la creación de herramientas y modelos accesibles ha impulsado su adopción. Los economistas reconocen que el ML no solo optimiza la capacidad predictiva, sino que también mejora significativamente la identificación causal en diversos fenómenos económicos [33].

Dada su creciente relevancia, el Machine Learning posee numerosas aplicaciones en el ámbito económico. Una de sus aplicaciones más destacadas es la predicción de variables macroeconómicas, una capacidad de gran valor para muchos países. Es crucial reconocer el impacto significativo que la inteligencia artificial y el machine learning tienen en la macroeconomía internacional y el comercio [17].

Por ejemplo, el estudio de Wohl and Kennedy [16], que explora el potencial de las redes neuronales para predecir el comercio internacional, con el objetivo de superar las limitaciones de los métodos econométricos tradicionales al tratar con grandes volúmenes de datos y relaciones complejas. Utilizando un modelo de gravedad, se analiza el comercio bilateral como variable dependiente, mientras que como variables explicativas se incorporan la distancia, los PIB de exportador e importador, y variables *dummy* que capturan factores como idioma común o acuerdos comerciales, junto con efectos fijos por país y por país-año. La metodología consiste en dividir el conjunto de datos en entrenamiento (70 %) y prueba (30 %), comparando el desempeño de un modelo de Mínimos Cuadrados Ordinarios (MCO), uno de Máxima Verosimilitud de Poisson (PPML) y una red neuronal, evaluados mediante el error cuadrático medio (RMSE) bajo tres configuraciones: un modelo base, otro con efectos fijos por país y uno con efectos fijos país-año. Los resultados muestran que la red neuronal con efectos fijos de país genera las estimaciones fuera de muestra más precisas (RMSE de $744 millones), superando a los modelos tradicionales. Además, el estudio destaca que la red neuronal puede alcanzar una precisión comparable a la de modelos más complejos, utilizando un número significativamente menor de variables, lo que sugiere su capacidad para capturar interacciones no lineales que escapan a MCO y PPML. Esta conclusión se refuerza con las predicciones acertadas del comercio real de Estados Unidos fuera del período de muestra. [16]

Jošić and Žmuk [17] se centran en la aplicación del aprendizaje automático para pronosticar el comercio internacional bilateral de

Croacia. Utilizando datos correspondientes al período 2001–2019 y variables derivadas del modelo de gravedad del comercio, los autores emplean algoritmos como procesos gaussianos, regresión lineal y, especialmente, el perceptrón multicapa (red neuronal). Sus hallazgos revelan una notable capacidad predictiva de los algoritmos de ML en este contexto, destacando al perceptrón multicapa como el de mejor rendimiento para las proyecciones de importaciones y exportaciones. Esta investigación subraya la relevancia de la IA y el ML para la toma de decisiones económicas y la formulación de políticas, al proporcionar información oportuna sobre futuras tendencias comerciales [17].

Recientemente, Sellami et al. [18] proponen el uso de Redes Neuronales Gráficas (GNNs), particularmente las Redes Convolucionales Gráficas (GCNs) y las Redes de Atención Gráfica (GATs), para modelar los complejos flujos comerciales. A diferencia de los modelos de regresión tradicionales, que presentan dificultades al enfrentar grandes volúmenes de datos, y en comparación con técnicas más convencionales de *Machine Learning* como el Random Forest (RF), este estudio demuestra la superioridad de las GNNs en términos predictivos. Utilizando datos detallados de comercio bilateral extraídos de la base UN Comtrade, los autores evidencian que las GNNs—en especial las GATs—superan de forma consistente a los modelos RF en métricas clave como el Error Cuadrático Medio (MSE) y el coeficiente de determinación R^2, lo que confirma su capacidad para capturar relaciones no lineales y dependencias estructurales en las redes de comercio global [18].

No obstante estos avances, la naturaleza compleja, heterogénea y voluminosa de los datos oficiales de comercio exterior continúa representando un desafío significativo. Estos conjuntos de datos, que abarcan múltiples productos, orígenes y destinos, suelen presentar estructuras no triviales, ruido, registros faltantes o inconsistentes, lo que dificulta el análisis directo y afecta la precisión de los modelos predictivos [11]. La diversidad de fuentes oficiales y la variabilidad temporal incrementan aún más esta complejidad, constituyendo obstáculos para la aplicación efectiva de modelos tradicionales [11, 14].

En consideración a los desafíos señalados, la incorporación de técnicas complementarias para organizar y segmentar la información adquiere particular relevancia. Métodos como el clustering permiten agrupar datos en subconjuntos homogéneos basados en similitudes internas, facilitando la identificación de patrones ocultos, la reducción de dimensionalidad y la detección de outliers, lo que contribuye a mejorar la interpretabilidad y robustez de los análisis posteriores [14, 20]. Estas técnicas no supervisadas resultan especialmente adecuadas para conjuntos de datos complejos y no etiquetados, como los del comercio exterior, donde la segmentación favorece la modelación y predicción de flujos comerciales [14].

Como muestra, Acero Carrión [11] diseñó un modelo basado en Big Data y machine learning para el análisis de datos de comercio exterior ecuatoriano, destacando la importancia de superar retos derivados del volumen, ruido y diversidad de datos mediante clustering para organizar la información y mejorar la precisión de las predicciones.

Gonzáles Argote and Ticona Gonzáles [34] aplicaron algoritmos de clustering no supervisado —como K-means y Partitioning Around Medoids (PAM)— para clasificar 188 países según sus características logísticas y costos comerciales, utilizando datos del Banco Mundial entre 2005 y 2014. Las variables consideradas —tiempo y costo para exportar e importar un contenedor— capturan dimensiones esenciales del comercio internacional, permitiendo un análisis que supera las clasificaciones geográficas tradicionales.

La metodología consistió en identificar agrupamientos principales que diferenciaron países con bajos costos y tiempos comerciales de aquellos con mayores barreras logísticas. Para validar los resultados, se evaluó la precisión de la clasificación, alcanzando niveles cercanos al 89 %. Demostrando, con este enfoque cómo el clustering organiza datos complejos y no estructurados, facilitando información interpretable de grandes volúmenes heterogéneos [34].

Torti et al. [35] proponen una metodología robusta y semiautomática de clustering de regresión. Esta técnica está diseñada para enfrentar desafíos propios de datos comerciales reales, como la presencia de outliers, estructuras latentes complejas y subpoblaciones ocultas dentro de categorías aduaneras homogéneas.

La propuesta sistematiza la selección de parámetros clave —número de clusters, nivel de

trimming y factor de restricción— mediante criterios de información extendidos, minimizando la subjetividad y aumentando la estabilidad de las soluciones. Complementada con visualizaciones innovadoras como el car-bike plot, esta metodología permite detectar transformaciones estructurales en los mercados que métodos convencionales no captan.

Su aplicación en datos reales de importaciones de mascarillas en la Unión Europea ilustra cómo el clustering robusto puede adaptarse a contextos con datos ruidosos y heterogéneos, características similares a las de los registros oficiales bolivianos. Además, la incorporación de mecanismos rigurosos de validación y la posibilidad de ponderar variables críticas ofrecen un marco adaptable para el análisis y pronóstico del comercio exterior en Bolivia [35].

Venegas Martínez and Jiménez Preciado [36] amplían el enfoque metodológico mediante un clustering multialgorítmico aplicado a la incertidumbre de política económica (EPU) en 16 economías desarrolladas y emergentes. Utilizando datos mensuales entre 2013 y 2024 y combinando K-means, análisis jerárquico aglomerativo (AHC) y DBSCAN, su estudio captura dinámicas latentes en datos altamente volátiles y no estructurados, superando clasificaciones convencionales basadas en regiones o niveles de ingreso.

Los clusters identificados durante la crisis financiera global de 2008–2009 y la crisis de la deuda soberana europea evidencian cómo diferentes economías experimentan niveles variables de incertidumbre, reflejando la sensibilidad del EPU a shocks globales y regionales [36].

En conjunto, estos estudios subrayan el potencial del clustering, especialmente cuando se integra con métodos como las redes neuronales, para transformar datos oficiales complejos de comercio exterior en información procesable y pronósticos confiables. Esta estrategia metodológica ofrece un enfoque analítico robusto, adecuado para abordar la heterogeneidad y volatilidad inherentes a los datos de comercio exterior, lo que la convierte en una herramienta útil para el análisis y la formulación de políticas económicas en contextos como el boliviano.

3 Gestión de Datos: Enfoque ELT

El procesamiento de información de comercio exterior en Bolivia enfrenta restricciones significativas relacionadas con la disponibilidad, estructura y estandarización de los datos publicados por el Instituto Nacional de Estadística (INE). La información se encuentra usualmente en archivos Excel con múltiples hojas, encabezados variables y una falta de consistencia temporal entre los registros. Estas características dificultan la automatización de los procesos analíticos y limitan su reproducibilidad. Frente a este contexto, se ha adoptado un enfoque basado en la estrategia **Extract-Load-Transform (ELT)**, ampliamente utilizada en sistemas de ingeniería de datos modernos [37].

La etapa de **extracción** consiste en la recopilación masiva y sistemática de los archivos anuales disponibles desde 1992. Este proceso implica técnicas de lectura, filtrado estructural y validación preliminar de los datos recolectados.

La fase de **carga** contempla el almacenamiento intermedio de los datos en un formato de alto rendimiento y orientado a columnas (como Parquet), que permite eficiencia en la consulta y manipulación de grandes volúmenes de datos [38]. Este almacenamiento favorece la trazabilidad y modularización del análisis posterior, integrándose en flujos automatizados basados en principios de analítica reproducible [39].

Finalmente, la etapa de **transformación** incluye procedimientos para estandarizar nombres de variables, homogenizar códigos de productos según nomenclaturas armonizadas (como la NANDINA y la clasificación CIIU), y reconstruir calendarios mensuales completos. Una decisión metodológica clave es la asignación de ceros explícitos en aquellos meses donde no se registran transacciones para una determinada combinación de producto y clase económica, bajo la hipótesis de ausencia real de comercio. Esta estrategia evita sesgos generados por imputaciones arbitrarias y mantiene la integridad temporal de las series [40]. Teniendo como resultado dos datasets; a nivel de actividad económica (CIIU) y a nivel de productos (NANDINA), las variables en las que se centra el análisis son:

- Valor de exportación (VALOR): Valor Total de las Exportaciones en Dólares
- Valor de importación (FRO): Valor Total de las importaciones en Dólares
- Saldo comercial: $saldo = VALOR - FRO$

A efectos del análisis posterior, para el periodo 2023 en adelante y para la variable del saldo comercial las series son estandarizadas. Esta transformación permite neutralizar efectos de escala y facilitar comparaciones entre productos heterogéneos [41].

Las series procesadas conservan una granularidad mensual desde 1992 y abarcan 146 actividades económicas (CIIU) y 11148 productos (NANDINA). La trazabilidad del proceso se asegura mediante control de versiones y documentación detallada. Todo el flujo se estructura bajo el paradigma de *Reproducible Analytical Pipelines* (RAP), promovido por oficinas estadísticas modernas para garantizar transparencia y actualización sistemática de los análisis [42].

4 Metodología

La metodología se estructura en dos componentes principales: agrupamiento de series temporales según sus patrones dinámicos y predicción de tendencias futuras utilizando modelos no lineales. Ambas etapas se diseñan para identificar comportamientos similares entre productos y proyectar su evolución en el corto plazo.

La figura 1 presenta el esquema metodológico.

Figura 1: Esquema de la metodología: desde la obtención de datos hasta el análisis predictivo y agrupamiento.

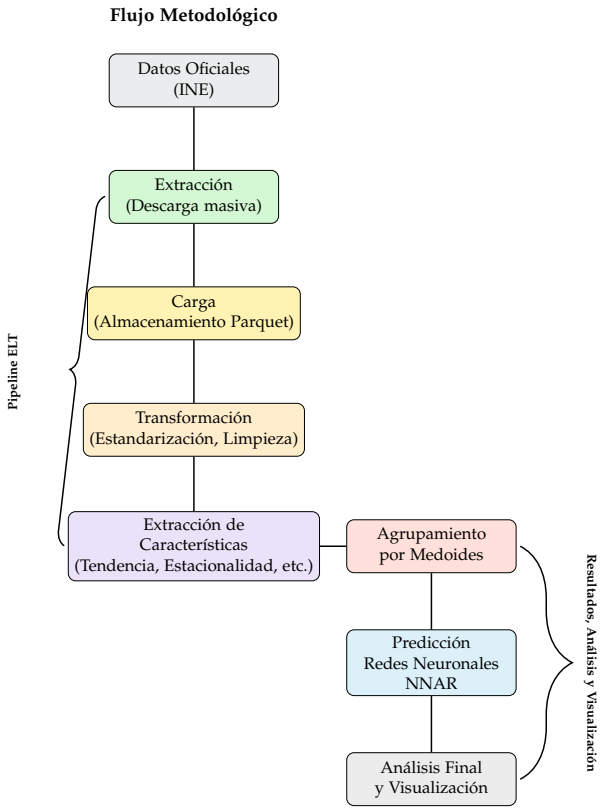

Fuente: Elaboración propia

4.1 Agrupamiento por Medoides

El análisis de conglomerados se realiza mediante la técnica de agrupamiento **medoides**, que pertenece a la familia de los métodos particionales robustos. Esta técnica busca dividir un conjunto de objetos en k grupos, minimizando la disimilitud interna. A diferencia de los métodos de medias, los medoides utilizan observaciones reales como centros de cada grupo, lo que los hace menos sensibles a valores extremos [43].

El procedimiento comienza con la construcción de un conjunto de características estadísticas para cada serie temporal, incluyendo métricas como:

- Fuerza de tendencia y estacionalidad
- Autocorrelación y autocorrelación parcial
- Entropía espectral y complejidad
- Cambios estructurales

Cada serie x_i se representa mediante un vector $\mathbf{x}_i \in \mathbb{R}^p$ de p características. La disimilitud entre series se calcula mediante la distancia euclídea entre sus representaciones estandarizadas:

$$d(x_i, x_j) = \sqrt{\sum_{k=1}^{p} (z_{ik} - z_{jk})^2} \tag{1}$$

La estandarización se realiza a nivel de características, garantizando que ninguna domine el agrupamiento por diferencia de escala. El número óptimo de grupos k se selecciona maximizando el índice de silueta promedio:

$$s_i = \frac{b_i - a_i}{\text{máx}(a_i, b_i)} \tag{2}$$

donde a_i es la disimilitud media del objeto i con los miembros de su propio grupo, y b_i la menor disimilitud media con cualquier otro grupo. El valor promedio de s_i para todos los objetos indica la calidad global de la partición [44].

4.2 Predicción con Redes Neuronales Autorregresivas

Para cada grupo de series identificado, se estima un modelo predictivo basado en **Redes Neuronales Autorregresivas** (NNAR). Este enfoque combina estructuras de redes *feedforward* con información lag del propio proceso, resultando adecuado para modelar relaciones no lineales en datos secuenciales [45].

El modelo NNAR se expresa como:

$$y_t = \alpha + \sum_{i=1}^{k} w_i \cdot \phi \left(\sum_{j=1}^{p} v_{ij} y_{t-j} + b_i \right) + \epsilon_t \quad (3)$$

donde y_t es el valor de la serie en el tiempo t, $\phi(\cdot)$ es una función de activación no lineal (típicamente sigmoidal), w_i y v_{ij} son los pesos de conexión, b_i los sesgos, y ϵ_t el error aleatorio.

La arquitectura se denota como NNAR$(p, P, k)[m]$, donde:

- p: número de retardos no estacionales
- P: número de retardos estacionales
- k: número de neuronas en la capa oculta
- m: periodicidad (12 para datos mensuales)

Los parámetros del modelo se ajustan minimizando la función de error cuadrático medio en un esquema de validación cruzada con origen rodante. Esta técnica preserva la estructura temporal y evalúa el desempeño del modelo de forma progresiva, sin contaminar el pasado con datos futuros [46].

Los resultados de la predicción se evalúan mediante métricas comunes en la literatura de series temporales:

$$MAE = \frac{1}{n} \sum_{t=1}^{n} |y_t - \hat{y}_t| \quad (4)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^{n} (y_t - \hat{y}_t)^2} \quad (5)$$

$$MAPE = \frac{100}{n} \sum_{t=1}^{n} \left| \frac{y_t - \hat{y}_t}{y_t} \right| \quad (6)$$

El **MASE** (Mean Absolute Scaled Error) se calcula como:

$$\text{MASE} = \frac{1}{T} \sum_{t=1}^{T} \left(\frac{|y_t - \hat{y}_t|}{\frac{1}{T-1} \sum_{t=2}^{T} |y_t - y_{t-1}|} \right) \quad (7)$$

Donde:

- y_t: Valor observado en el tiempo t.
- $\hat{y}_t$: Valor predicho por el modelo en el tiempo t.
- $|y_t - \hat{y}_t|$: Error absoluto del modelo.
- $\frac{1}{T-1} \sum_{t=2}^{T} |y_t - y_{t-1}|$: Error absoluto medio del modelo ingenuo.
- T: Número total de observaciones.

Para contrastar el rendimiento que se obtiene con la NNAR se corren modelos de suaviazamiento exponencial y modelos ARIMA-SARIMA y se comparan mediante el MASE

5 Resultados del Clustering

Como se mencionó en la metodología, se emplea la técnica de medoides. Esta se aplica a los dos conjuntos de datos definidos para el período 2023 en adelante[1].

Tabla 1: Coeficiente de silueta promedio por grupo

k	Silueta CIIU	Silueta NANDINA
4	0.0959	0.0990
5	0.0943	0.0828
6	0.0842	**0,1013**
7	0.0906	0.0855
8	0.0935	0.0939
9	0.0883	0.0849
10	0.0950	0.0979
11	0.0901	0.0839
12	**0,0984**	0.0818
13	0.0981	0.0802
14	0.0897	0.0682
15	0.0905	0.0708
16	0.0853	0.0769
17	0.0874	0.0761
18	0.0801	0.0787
19	0.0825	0.0820
20	0.0903	0.0840

Fuente: Elaboración propia.

[1] La elección de este corte es ad hoc y está orientada principalmente a captar el comportamiento de los últimos años

Se selecciona el valor óptimo de k dentro del rango de 4 a 20 posibles grupos. Para las actividades económicas, se obtiene un valor óptimo de $k = 12$, y para los productos, $k = 6$. La Tabla 1 presenta los valores del coeficiente de silueta correspondientes a los distintos valores de k en ambos conjuntos de datos.

Se definió como grupo aislado de las actividades o productos a aquellas series que, durante el período de análisis (2023 en adelante), no registraron actividad; este conjunto corresponde al grupo 0. En cuanto a los resultados del agrupamiento, las Tablas 2 y 3 presentan estadísticas del saldo comercial correspondiente al año 2025, con el objetivo de facilitar la interpretación de los grupos identificados.

Tabla 2: Estadísticas del saldo comercial de 2025, según clúster (CIIU)

Clúster	Total	Mínimo	Máximo	Casos
0	0.00	0.00	0.00	8
1	−82144791.90	−20509731.48	13093146.35	28
2	−345039923.58	−46997748.27	3029931.07	56
3	892651140.66	−38786385.00	276738161.34	40
4	−216160096.02	−23495875.08	723758.46	64
5	−1079814356.49	−354668083.90	957725.39	72
6	−275111851.06	−20476185.78	16123654.50	68
7	−6699971.00	−1206980.00	0.00	28
8	−125869838.15	−14963036.82	0.00	40
9	949846300.40	−9081953.86	161626511.92	32
10	−39633541.73	−6676392.18	1515559.85	36
11	3896433.11	−7504951.85	17825895.56	44
12	−247027876.74	−21842627.47	6383144.59	72

Fuente: Elaboración propia

Tabla 3: Estadísticas del saldo comercial de 2025, según clúster (NANDINA)

Clúster	Total	Mínimo	Máximo	Casos
0	−8607174.46	−2778986.00	1561930.11	18632
1	−91592954.37	−19144283.00	180000.00	6004
2	−203473753.29	−5631427.66	17535807.14	3500
3	−848522975.43	−99424192.00	14114814.49	6548
4	−920197100.64	−234415657.00	3591833.83	5544
5	1547842641.96	−12879024.00	124898489.60	3608
6	−46557056.27	−10159034.00	1670593.82	756

Fuente: Elaboración propia

En el caso de las actividades económicas, el grupo 9 representa la mayor contribución positiva al saldo comercial, mientras que el clúster 5 concentra la diferencia negativa más pronunciada, lo cual se ilustra en la Figura 2. Para los productos, se observa un patrón similar: el clúster 5 agrupa aquellos con mejor desempeño exportador, mientras que el clúster 4 concentra los de menor rendimiento. Este contraste se visualiza con mayor claridad en la Figura 3.

Finalmente, para ofrecer una visión más integral de los resultados del agrupamiento se presenta la figura 4 para las actividades, se omite el despliegue para los productos al tener mas de 11k productos a visualizar.

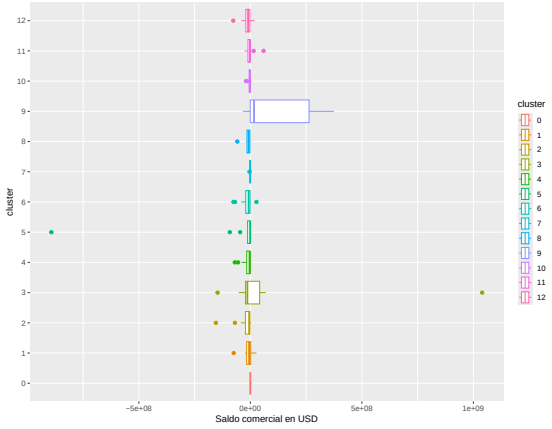

Figura 2: Dispersión del saldo comercial según cluster, CIIU. Fuente: Elaboración Propia

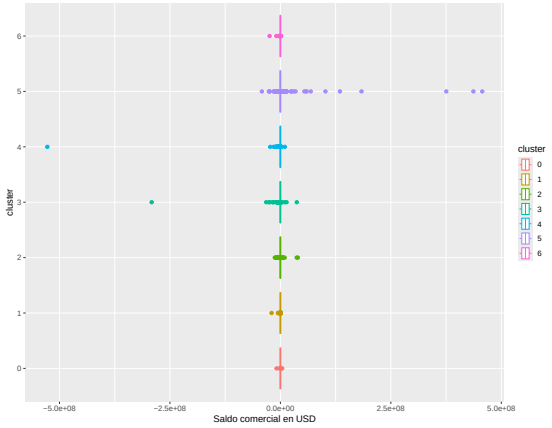

Figura 3: Dispersión del saldo comercial según cluster, NANDINA. Fuente: Elaboración Propia

Para complementar la interpretación de los clústeres, se construyó un gráfico con las trayectorias temporales del saldo comercial estandarizado para cada grupo de actividades económicas (Figura 5). Este recurso permite visualizar de forma comparativa la dinámica de los clústeres a lo largo del período, mostrando la persistencia de superávits o déficits en determinados sectores. Se observa que los clústeres 9 y 3 concentran superávits sostenidos, mientras que los clústeres 5 y 12 reflejan déficits persistentes. Esta evidencia respalda la validez de la segmentación y refuerza el vínculo entre la clasificación estadística y la realidad económica de los sectores.

Para facilitar la interpretación sectorial de

Figura 4: Código CIIU según cluster

Fuente: Elaboración Propia

Figura 5: Trayectorias del saldo comercial por clúster de actividades económicas (CIIU)

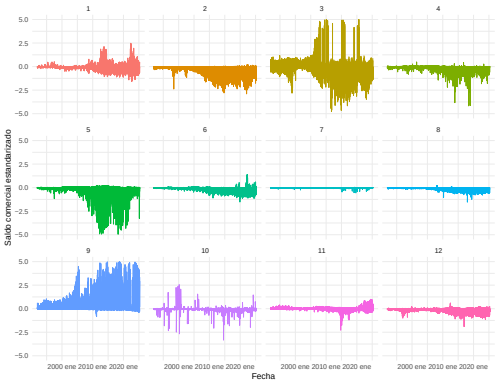

Fuente: Elaboración Propia

los clústeres, se presentan ejemplos ilustrativos de actividades económicas seleccionadas aleatoriamente en cada grupo. Esta muestra permite vincular la segmentación estadística con actividades concretas de la economía boliviana (Ver Tabla 4).

Además de la clasificación por CIIU, se generó una segmentación alternativa a nivel de partidas NANDINA. La Figura 6 muestra las trayectorias temporales del saldo comercial estandarizado en cada clúster, lo que permite contrastar la dinámica sectorial con una desagregación más fina de productos.

En este caso, el clúster 5 agrupa las series con un mejor desempeño en el saldo comercial, mientras que el clúster 4 muestra un desempeño negativo a lo largo del tiempo. Por su parte, el clúster 3 reúne series que tuvieron un comportamiento positivo hace aproximadamente 10 años, seguido de una caída pronunciada en los últimos años. Finalmente la Tabla 5 presenta una muestra aleatoria de 3 series según los cluster.

Tabla 4: Ejemplos de actividades económicas (CIIU) seleccionadas aleatoriamente por clúster

CIIUR3	Clúster	DESCIIU
4020	0	Fabricación de gas; distribución de combustibles gaseosos por tuberías
1200	0	Extracción de minerales de uranio y de torio
2429	1	Fabricación de otros productos químicos n.c.p.
3699	1	Otras industrias manufactureras n.c.p.
2710	2	Industrias básicas de hierro y de acero
3140	2	Fabricación de acumuladores y de pilas eléctricas
1320	3	Extracción de minerales metalíferos no ferrosos, excepto minerales de uranio y de torio
1711	3	Preparación e hilatura de fibras textiles: tejedura de productos textiles
2924	4	Fabricación de maquinaria para la explotación de minas y canteras y para obras de construcción
2911	4	Fabricación de motores y turbinas, excepto motores para aeronaves y vehículos automotores
2413	5	Fabricación de plásticos en formas primarias y de caucho sintético
2320	5	Fabricación de productos de la refinación del petróleo
2423	6	Fabricación de productos farmacéuticos, sustancias químicas medicinales y productos botánicos
3130	6	Fabricación de hilos y cables aislados
2927	7	Fabricación de armas y municiones
3520	7	Fabricación de material ferroviario rodante
2899	8	Fabricación de otros productos elaborados de metal n.c.p.
2922	8	Fabricación de máquinas herramientas
1514	9	Elaboración de aceites y grasas de origen vegetal y animal
1110	9	Extracción de petróleo crudo y de gas natural
2893	10	Fabricación de artículos de cuchillería, herramientas de mano y artículos de ferretería
3530	10	Fabricación de aeronaves y naves espaciales
2010	11	Aserrado y cepillado de la madera
1511	11	Producción, transformación y conservación de carne y de derivados cárnicos
2520	12	Fabricación de productos de plástico
2422	12	Fabricación de pinturas, barnices y productos de revestimiento similares, tinta de imprenta

Fuente: Elaboración propia

6 Resultados de la Predicción

Para evaluar los resultados obtenidos en el modelado con redes neuronales autorregresivas (NNAR), es fundamental considerar el volumen de datos. Dado que se trata de más de 10,000 series temporales, resulta poco práctico presentar individualmente los resultados para cada serie[2]. Por ello, se optó por dos criterios de evaluación: en primer lugar, comparar el rendimiento de las NNAR frente a los métodos de suavizamiento exponencial y ARIMA/SARIMA mediante el Mean Absolute Scaled Error (MASE); en segundo lugar, desplegar

[2] En el repositorio digital se encuentran disponibles los archivos que contienen los conjuntos de datos y los modelos correspondientes.

Figura 6: Trayectorias del saldo comercial por clúster de código NANDINA

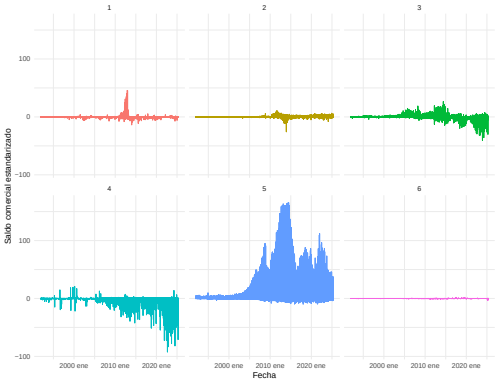

Fuente: Elaboración Propia

Tabla 5: Ejemplos de NANDINA seleccionadas aleatoriamente por clúster

NANDINA	Clúster	Descripción
0603104000	0	ROSAS FRESCAS
8802120000	0	HELICOPTEROS DE PESO EN VACIO SUPERIOR A 2.000 KG
8703239029	0	LOS DEMAS VEHICULOS CON MOTOR DE EMBOLO (PISTON) ALTERNATIVO, DE ENCENDIDO POR CHISPA, DE CILINDRADA SUPERIOR A 1.500 CM3 PERO INFERIOR O IGUAL A 3.000 CM3,
8504230000	1	TRANSFORMADORES DE DIELECTRICO LIQUIDOS,DE POTENCIA SUPERIOR A 10.000 kVA
7112910000	1	DESPERDICIOS Y DESECHOS, DE METAL PRECIOSO O DE CHAPADO DE METAL PRECIOSO, DE ORO O DE CHAPADO (PLAQUE) DE ORO, EXCEPTO LAS BARREDURAS QUE CONTENGAN OTRO METAL PRECIOSO
8526100000	1	APARATOS DE RADIODETECCION Y RADIO SONDEO (RADAR).
8429200000	2	NIVELADORAS,AUTOPROPULSADAS
7614100000	2	CABLES TRENZAS Y ARTICULOS SIMILARES DE ALUMINIO SIN AISLAR PARA USOS ELEC TRICOS CON ALMA DE ACERO
8411990000	2	LAS DEMAS PARTES DE LAS DEMAS TURBINAS DE GAS
3701100000	3	PLACAS Y PELICULAS PLANAS PARA RAYOS X.
8539229000	3	LAS DEMAS LAMPARAS Y TUBOS DE INCANDESCENCIA EXCEPTO LAS DE RAYOS ULTRAVIOLETAS O INFRARROJOS.DE POTENCIA INFERIOR O IGUAL A 200 W Y PARA UNA TENSION SUPERIOR A 100 V
9403500000	3	MUEBLES DE MADERA DEL TIPO DE LOOS UTILIZADOS EN LOS DORMITORIOS.
8443160000	4	MAQUINAS Y APARATOS PARA IMPRIMIR, FLEXOGRAFICOS
8802400000	4	AVIONES Y DEMAS AERONAVES. DE PESO EN VACIO SUPRIOR A 15.000 Kg.
2710192100	4	GASOILS (GASOLEO) (DIESEL)
2711210000	5	GAS NATURAL EN ESTADO GASEOSO
2616100000	5	MINERALES DE PLATA Y SUS CONCENTRADOS
0801220000	5	NUECES DEL BRASIL SIN CASCARA,FRESCOS O SECOS
2523100000	6	CEMENTO SIN PULVERIZAR (CLINKER).
8422409000	6	LAS DEMAS MAQUINAS Y APARATOS PARA EMPAQUETAR O ENVOLVER MERCANCIAS (INCLUIDAS LAS DE ENVOLVER CON PELICULA TERMORRETRACTIL)
8515809000	6	LAS DEMAS MAQUINAS Y APARATOS PARA SOLDAR DE ARCO

Fuente: Elaboración propia

los resultados del modelado para el top 10 de actividades y productos según el saldo comercial en 2025.

Las figuras 7 y 8 muestran los rendimientos comparativos, mientras que las tablas 6 y 7 presentan el modelado correspondiente para las series seleccionadas.

Figura 7: Comportamiento del MASE según método de predicción, CIIU

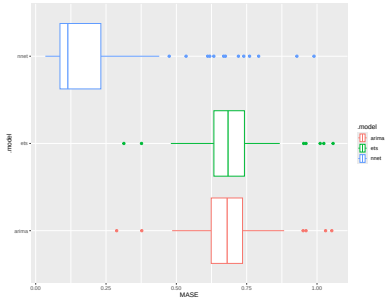

Fuente: Elaboración Propia

Figura 8: Comportamiento del MASE según método de predicción, NANDINA

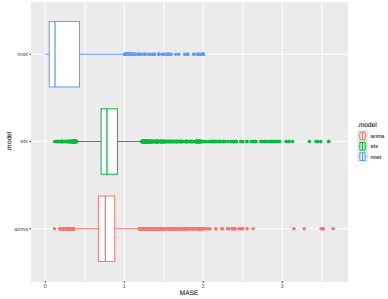

Fuente: Elaboración Propia

Los resultados reflejan una clara dominancia del enfoque NNAR en términos de MASE, tanto para actividades económicas como para productos, mientras que las técnicas de suavizamiento exponencial y ARIMA presentan desempeños similares entre sí.

Además de las redes neuronales autorregresivas (NNAR), se realizaron pruebas exploratorias con arquitecturas de aprendizaje profundo, en particular modelos LSTM aplicados a un subconjunto reducido de series representativas. Si bien los resultados preliminares muestran desempeños comparables a las NNAR en términos de MASE, el costo computacional fue considerablemente mayor, lo que limita su aplicabilidad a gran escala en el presente estudio. No obstante, estos ensayos confirman la viabilidad de extender el marco metodológico hacia arquitecturas más sofisticadas, como LSTM y redes neuronales gráficas (GNNs), cuya incorporación constituye una agenda futura de in-

Tabla 6: Modelado del top 10 para el saldo comercial de 2025, CIIU

CIIUR3	Saldo	ARIMA	ETS	NNAR	Clúster
1320	1039483506	ARIMA(0,1,1)	ETS(M,N,M)	NNAR(15,1,8)[12]	3
1110	374439926	ARIMA(0,1,3)(0,0,1)[12]	ETS(M,A,N)	NNAR(26,1,14)[12]	9
2720	341964956	ARIMA(0,1,3)	ETS(A,N,N)	NNAR(21,1,11)[12]	9
1514	236844764	ARIMA(1,0,1)(0,1,1)[12] w/ drift	ETS(M,N,M)	NNAR(25,1,13)[12]	9
0113	68818877	ARIMA(3,1,2)	ETS(M,A,M)	NNAR(26,1,14)[12]	3
1511	59401329	ARIMA(1,1,1)(0,0,2)[12] w/ drift	ETS(A,N,A)	NNAR(18,1,10)[12]	11
3691	57482627	ARIMA(0,1,1)(0,0,2)[12]	ETS(A,N,A)	NNAR(26,1,14)[12]	3
0111	27879027	ARIMA(0,1,4)(0,0,2)[12]	ETS(A,N,A)	NNAR(20,1,10)[12]	1
2412	27555582	ARIMA(1,1,5)	ETS(A,N,N)	NNAR(25,1,13)[12]	6
3710	19423501	ARIMA(0,1,1)(0,0,1)[12]	ETS(A,N,A)	NNAR(26,1,14)[12]	12

Fuente: Elaboración propia

Tabla 7: Modelado del top 10 para el saldo comercial de 2025, NANDINA

NANDINA	Saldo	ARIMA	ETS	NNET	Cluster
2608000000	456897950	ARIMA(0,1,1)	ETS(M,N,M)	NNAR(26,1,14)[12]	5
2616100000	436876134	ARIMA(0,1,1)(0,0,1)[12]	ETS(M,A,N)	NNAR(14,1,8)[12]	5
2711210000	375497574	ARIMA(0,1,1)(0,0,1)[12]	ETS(M,Ad,M)	NNAR(25,1,13)[12]	5
7108120000	183689785	ARIMA(2,1,3)(0,0,1)[12]	ETS(A,N,N)	NNAR(26,1,14)[12]	5
8001100000	134775321	ARIMA(3,1,0)(0,0,2)[12]	ETS(M,N,M)	NNAR(26,1,14)[12]	5
2304000000	102062363	ARIMA(1,0,4)(0,1,1)[12] w/ drift	ETS(M,A,M)	NNAR(26,1,14)[12]	5
2607000000	68747836	ARIMA(0,1,1)(0,0,1)[12]	ETS(A,N,N)	NNAR(26,1,14)[12]	5
7113190000	59185323	ARIMA(1,1,3)(0,0,1)[12]	ETS(A,N,A)	NNAR(12,1,6)[12]	5
1507100000	58301575	ARIMA(1,1,2)(0,0,2)[12]	ETS(A,N,A)	NNAR(26,1,14)[12]	5
801220000	54276072	ARIMA(1,0,2)(0,1,1)[12] w/ drift	ETS(A,N,A)	NNAR(26,1,14)[12]	5

Fuente: Elaboración propia

vestigación para capturar dependencias estructurales más complejas en los flujos comerciales.

Para complementar estos resultados se realizó el procedimiento de validación *Holdout*. Este se detalla en el anexo, se detalla cómo se dividieron los datos en conjuntos de entrenamiento y prueba, los modelos ajustados (ARIMA, ETS y NNETAR) y la evaluación de su desempeño fuera de muestra.

7 Visualización Interactiva y Plataforma de Pronósticos

Como parte del esfuerzo por democratizar el acceso a herramientas de análisis predictivo basadas en técnicas de aprendizaje automático, se ha desarrollado una plataforma interactiva implementada mediante **Shiny**, una tecnología de código abierto que permite construir aplicaciones web dinámicas a partir de lenguajes estadísticos. Esta plataforma opera como un *dashboard* accesible vía navegador, integrando visualizaciones gráficas, opciones de filtrado y reportes automáticos para facilitar la exploración y proyección de las series de comercio exterior procesadas.

El objetivo de esta solución tecnológica es extender la utilidad de los modelos generados más allá de círculos técnicos, permitiendo que diversos públicos —como emprendedores, estudiantes universitarios, funcionarios de gobierno, analistas de comercio y pequeñas empresas— puedan generar pronósticos personalizados y detectar oportunidades comerciales a partir de datos históricos.

El panel permite:

- Consultar series mensuales por producto y clase económica desde 1992.
- Comparar agrupamientos dinámicos basados en similitud de comportamiento.
- Ejecutar pronósticos automáticos para productos específicos, con intervalos de confianza.
- Descargar resultados en formatos estándar (CSV, PNG, PDF).

El desarrollo del dashboard se encuentra alojado en un repositorio de GitHub, donde se detallan los pasos necesarios para su ejecución local, incluyendo requerimientos del entorno, dependencias y estructura de carpetas. Esta disposición promueve la transparencia, reproducibilidad y escalabilidad de la iniciativa, además de fomentar el aprendizaje práctico de herramientas de ciencia de datos aplicadas a problemas reales.

8 Conclusiones y recomendaciones

El presente estudio demuestra que la integración de técnicas avanzadas de aprendizaje automático, como el *clustering* no supervisado y las redes neuronales autorregresivas (NNAR), aporta un valor significativo al análisis del comercio exterior boliviano. La automatización del proceso de extracción, transformación y modelado de datos oficiales ha permitido superar las limitaciones de acceso y estructura de la información publicada por el INE,

Figura 9: Interfaz del tablero interactivo para pronósticos de comercio exterior (COMEX Turbo)

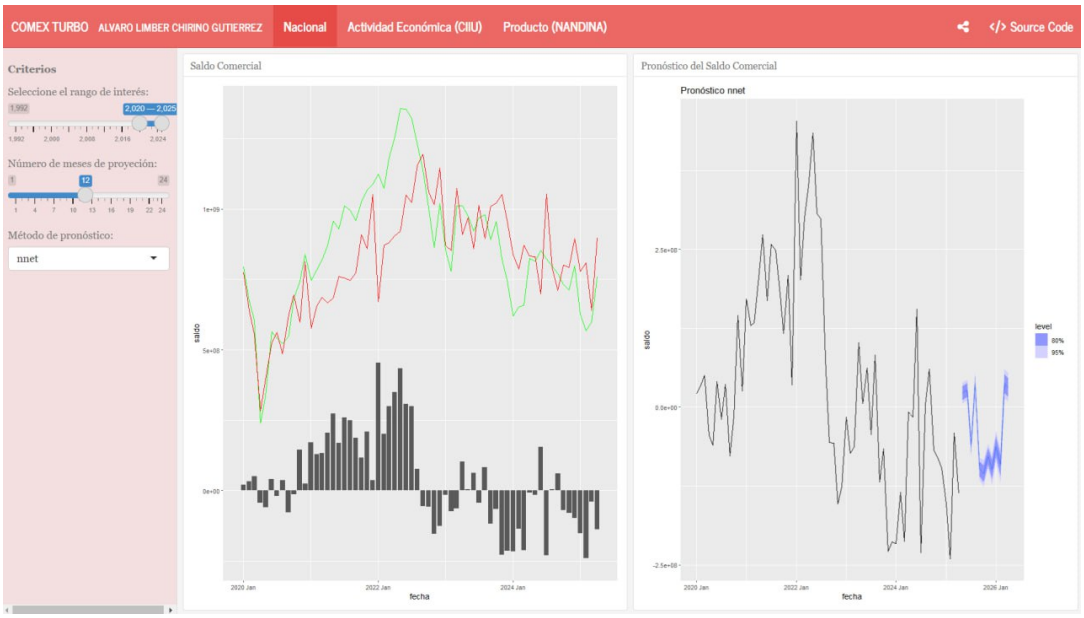

Fuente: Elaboración Propia

consolidando y estandarizando miles de series temporales desde 1992.

Este enfoque constituye una alternativa concreta para abordar los problemas estructurales identificados en la primera sección —concentración exportadora, baja diversificación productiva y fragmentación de los datos oficiales— que dificultan tanto el análisis predictivo como la formulación de políticas basadas en evidencia [4–6, 11]. Al combinar *pipelines* reproducibles, técnicas de *clustering* y modelos NNAR, se capturan relaciones complejas, se segmentan productos y sectores, y se generan predicciones robustas sobre los flujos comerciales.

Los resultados se articulan en tres dimensiones principales: metodológica, estratégica e institucional.

En el plano metodológico, el estudio valida la pertinencia de arquitecturas de aprendizaje automático para enfrentar la complejidad de las series temporales de comercio exterior. La superioridad sistemática de los modelos NNAR frente a enfoques tradicionales (ARIMA y ETS), medida a través del MASE, confirma que las relaciones inherentes a los flujos comerciales bolivianos son profundamente no lineales y exigen herramientas capaces de capturarlas con mayor precisión. Este hallazgo establece un nuevo estándar de robustez predictiva para la economía boliviana y demuestra que la incorporación de técnicas de *machine learning* es indispensable para un análisis dinámico y prospectivo en contextos de alta heterogeneidad de datos.

Desde la dimensión estratégica, la aplicación del *clustering* por medoides ofrece un diagnóstico diferencial de los sectores y productos. La segmentación de miles de series temporales en grupos dinámicos permite trascender los enfoques agregados y orienta la política económica hacia intervenciones más focalizadas. Por ejemplo, los clústeres con superávit persistente (como los grupos 3 y 9 en CIIU) sugieren consolidar ventajas comparativas, mientras que los clústeres con déficits crónicos (como el grupo 5) señalan cuellos de botella estructurales que deben convertirse en prioridades para políticas de sustitución de importaciones y fomento productivo. Este enfoque dota a la política industrial de mayor precisión y capacidad de impacto.

En el ámbito institucional, la construcción de un pipeline ELT automatizado y reproducible, junto con el desarrollo de un tablero interactivo en **Shiny**, constituye un salto cualitativo. Esta infraestructura no solo transforma los datos fragmentados del INE en un recurso estandarizado y accesible —alojado en un repositorio público de GitHub—, sino que también democratiza el acceso al análisis predictivo para el sector público, privado y académico. Al garan-

tizar trazabilidad, replicabilidad y transparencia, la iniciativa se alinea con las mejores prácticas internacionales de ciencia de datos y fortalece las capacidades nacionales de planificación estratégica en comercio exterior.

Estos hallazgos son consistentes con la literatura internacional que demuestra cómo el *machine learning* y la inteligencia artificial superan las limitaciones de los métodos econométricos tradicionales en entornos caracterizados por datos heterogéneos y relaciones no lineales [47–49]. En particular, la segmentación mediante *clustering* facilita la identificación de patrones homogéneos y dinámicas diferenciadas, lo que aporta evidencia útil para priorizar políticas industriales y estrategias comerciales [14, 50].

Asimismo, la adopción del enfoque Extract-Load-Transform (ELT) y de los Reproducible Analytical Pipelines (RAP) garantiza la actualización sistemática y confiable de los análisis, promoviendo la transparencia y consolidando evidencia robusta para orientar la diversificación productiva y la política comercial de Bolivia [11, 51, 52].

En términos de política económica, los resultados permiten identificar sectores con desempeños heterogéneos, priorizando así estrategias diferenciadas: políticas de fomento productivo e industrialización en los sectores con saldos negativos persistentes, y consolidación de ventajas comparativas en aquellos con superávit. La capacidad predictiva de los modelos, además, ofrece insumos valiosos para anticipar escenarios de balanza comercial y gestionar riesgos derivados de fluctuaciones internacionales de precios, fortaleciendo tanto la planificación estatal como la estrategia empresarial.

Recomendaciones

A partir de los hallazgos, se plantean las siguientes recomendaciones, fundamentadas en la literatura y conectadas con los problemas identificados:

1. **Mejorar la infraestructura de datos abiertos:** Publicar datos en formatos interoperables y estructurados, como Parquet o CSV, facilita análisis reproducibles y predictivos, alineándose con experiencias exitosas en Chile, México y Brasil [22–24].
2. **Capacitación continua en ciencia de datos y ML:** Fortalecer la formación de analistas y funcionarios públicos permite adoptar metodologías modernas, interpretar patrones complejos y generar información estratégica [26, 48].
3. **Fomentar colaboración interinstitucional:** La cooperación entre organismos públicos, universidades y centros de investigación contribuye a validar modelos, compartir buenas prácticas y generar metodologías robustas [53, 54].
4. **Actualización periódica de modelos predictivos:** Revisar y recalibrar modelos regularmente, incorporando nuevos datos y adaptándose a cambios en patrones comerciales, asegura precisión y utilidad para decisiones estratégicas [48, 55].
5. **Incorporar variables macroeconómicas y geopolíticas:** Integrar factores externos y sectoriales relevantes en los modelos mejora la precisión de los pronósticos y anticipa riesgos de fluctuaciones internacionales [7, 8].
6. **Desarrollar herramientas de visualización interactivas:** Dashboards que muestren resultados analíticos facilitan la interpretación de información por tomadores de decisiones y empresas, promoviendo transparencia y acceso a evidencia confiable [25, 26].

La combinación de metodologías reproducibles, técnicas avanzadas de ML y análisis de datos abiertos constituye una alternativa concreta para superar los problemas estructurales y analíticos del comercio exterior boliviano. Este enfoque permite generar evidencia estratégica para diversificación productiva, competitividad internacional y desarrollo económico sostenible, alineándose con los Objetivos de Desarrollo Sostenible (ODS 8, 9 y 16) y el Plan de Desarrollo Económico y Social (PDES 2025) [7, 27, 28].

Referencias

[1] Paul R. Krugman and Maurice Obstfeld. *International Economics: Theory and Policy*. Addison-Wesley, 1995.

[2] Bela Balassa. *The Structural Adjustment Policies in Developing Economies*. World Bank, 1980.

[3] José Antonio Ocampo. Latin america and

the global economy: A policy discussion. *Oxford Review of Economic Policy*, 30(3): 369–395, 2014.

[4] Raúl Prebisch. The economic development of latin america and its principal problems. *Economic Bulletin for Latin America*, 7(1):1–22, 1950.

[5] Ricardo Hausmann, Dani Rodrik, and Andrés Velasco. Growth diagnostics. *Journal of Economic Growth*, 12(1):1–25, 2007.

[6] Juan S. Blyde. Economic complexity and diversification in latin america. *World Development*, 96:243–256, 2017.

[7] Comisión Económica para América Latina y el Caribe. Perspectivas del comercio exterior en américa latina y el caribe. Technical report, ONU, CEPAL, 2019. URL https://www.cepal.org/es/publicaciones/perspectivas-comercio-exterior-america-latina-caribe. Disponible en línea.

[8] Nick Bachelet and Elena Torres. Geopolitical factors in international trade forecasting. *International Journal of Political Economy*, 45(1):99–115, 2021. doi: 10.2345/ijpe.2021.451. URL https://ipejournal.com/bachelet2021.

[9] Instituto Nacional de Estadística de Bolivia. Bases de datos de comercio exterior, 2024. URL https://www.ine.gob.bo/index.php/estadisticas-economicas/comercio-exterior/. Consultado en junio de 2025.

[10] Luis Torres. Data management challenges in latin american trade statistics. *Journal of Data and Information Science*, 8(2):150–168, 2023.

[11] Rudy Fabricio Acero Carrión. Modelo esquema para el análisis y tratamiento de la información en empresas ecuatorianas de comercio exterior mediante el uso de big data, 2021. URL https://dspace.ups.edu.ec/bitstream/123456789/23637/1/UPS-GT003986.pdf. Tesis que presenta un modelo para analizar y organizar datos heterogéneos, voluminosos y ruidosos en comercio exterior utilizando Big Data y técnicas de machine learning.

[12] Jeffrey D. Sachs and Andrew M. Warner. Resource curse or debt overhang? *The Economic Journal*, 112(482):69–84, 2001.

[13] Banco Central de Bolivia. Balanza de pagos de bolivia 2024. Technical report, Banco Central de Bolivia, apr 2025. URL https://www.bcb.gob.bo/webdocs/publicacionesbcb/2025/04/44/BOP%202024.pdf. Accessed on June 30, 2025.

[14] J. Méndez et al. Minería visual de datos para la toma de decisiones estratégicas en importaciones. *Revista Científica de Investigación y Tecnología*, 2020. URL https://portal.amelica.org/ameli/journal/844/8445128011/8445128011.pdf. Estudio aplicado con técnicas de clustering para segmentar datos complejos en comercio internacional, facilitando la interpretación y reducción de dimensionalidad.

[15] Daniel Levin and Maria Rosa. Limitations of econometric models in trade forecasting. *International Journal of Forecasting*, 33 (1):23–35, 2017.

[16] Isaac Wohl and Jim Kennedy. Neural network analysis of international trade. Working Paper ID-049, U.S. International Trade Commission (USITC), 2018. URL https://www.usitc.gov/publications/332/working_papers/neural_networks_and_international_trade_-_compiled_draft_06.pdf. Documento que presenta un análisis preliminar del uso de redes neuronales para modelar el comercio internacional.

[17] Hrvoje Jošić and Berislav Žmuk. A machine learning approach to forecast international trade: The case of croatia. 13(2): 1–12, 2022. ISSN 1847-9375. doi: 10.2478/bsrj-2022-0030. URL https://10.2478/bsrj-2022-0030.

[18] Bassem Sellami, Chahinez Ounoughi, Tarmo Kalvet, Marek Tiits, and Diego Rincon-Yanez. Harnessing graph neural networks to predict international trade flows. 8 (6):65. ISSN 2504-2289. doi: 10.3390/bdcc8060065. URL https://www.mdpi.com/2504-2289/8/6/65.

[19] Wen Li and Jing Zhao. Advanced machine learning techniques in economic forecasting. *Economic Modelling*, 120:105100, 2023.

[20] R. E. Bawack et al. La inteligencia artificial para la predicción y optimización en el comercio global. *Revista Iberoamericana de Inteligencia Artificial*, 2022. URL https://www.redalyc.org/journal/7219/721980753006/html/. Revisión del impacto de la inteligencia artificial, incluyendo machine learning y clustering, en la mejora de la gestión y predicción de datos heterogéneos y ruidosos en comercio internacional.

[21] Rui Xu and Donald Wunsch. A survey of clustering algorithms. *IEEE Transactions on Neural Networks*, 16(3):645–678, 2015.

[22] C. Wong-Dan and M. Flores. Aplicaciones de machine learning en el comercio exterior de chile. *Revista Latinoamericana de Economía Digital*, 5(2):45–62, 2022.

[23] J. F. Tinoco and M. Sánchez. Machine learning in enhancing the forecasting accuracy of currency exchange rates. *Journal of Financial Forecasting*, 2024. URL https://papers.ssrn.com/sol3/Delivery.cfm/abstractid=4937353. Preprint available at SSRN.

[24] M. F. Angulo Bustinza and collaborators. Deep learning for algorithmic trading: A systematic review and performance comparison. *Journal of Computational Finance*, 15(1):45–78, 2025. URL https://www.sciencedirect.com/science/article/pii/S2590005625000177.

[25] Jorge Ramos and Lucia Ferreyra. Digitalization and visualization tools in trade data analytics. *Journal of Digital Trade and Innovation*, 8(2):45–60, 2023. doi: 10.7890/jdti.2023.082. URL https://jdti.org/ramos2023.

[26] Lian Wu and Suresh Kumar. Policy data integration for strategic decision making in trade. *International Journal of Policy Analysis*, 28(1):78–95, 2023. doi: 10.5678/ijpa2023.2801. URL https://policyjournal.com/wu2023.

[27] United Nations. Transforming our world: the 2030 agenda for sustainable development, 2020. URL https://sdgs.un.org/2030agenda. Accessed: 2025-07-01.

[28] Ministerio de Planificación del Desarrollo. Plan de desarrollo económico y social 2021–2025: Reconstruyendo la economía para vivir bien, hacia la industrialización con sustitución de importaciones, 2021. URL https://www.planificacion.gob.bo/sites/folder/files/pdes_2021-2025_version_final.pdf. Gobierno del Estado Plurinacional de Bolivia.

[29] Feras Batarseh, Munisamy Gopinath, Ganesh Nalluru, and Jayson Beckman. Application of machine learning in forecasting international trade trends. URL https://arxiv.org/abs/1910.03112. Version Number: 1.

[30] Diego Rincon-Yanez, Chahinez Ounoughi, Bassem Sellami, Tarmo Kalvet, Marek Tiits, Sabrina Senatore, and Sadok Ben Yahia. Accurate prediction of international trade flows: Leveraging knowledge graphs and their embeddings. 35(10):101789. ISSN 13191578. doi: 10.1016/j.jksuci.2023.101789. URL https://linkinghub.elsevier.com/retrieve/pii/S1319157823003439.

[31] Juan Carlos Velasco Tinoco, Daniela Pauleth Ojeda Gonsaga, and Jorge Eduardo Arias Montero. El impacto de la inteligencia artificial en los operadores de comercio exterior en la ciudad de machala. 8(4): 2127–2143. ISSN 2707-2215, 2707-2207. doi: 10.37811/cl_rcm.v8i4.12454. URL https://ciencialatina.org/index.php/cienciala/article/view/12454.

[32] Kinza Yousfani, Moiz Qureshi, Muhammad Daniyal, and Muhammad Ismail. Comparative study of machine learning (ml) and conventional time series methodologies in modelling the exports trade of pakistan. 2(2):349–367. ISSN 2960-2203, 2960-219X. doi: 10.59075/ijss.v2i2.232. URL https://induspublishers.com/IJSS/article/view/232.

[33] Hugo Storm, Kathy Baylis, and Thomas Heckelei. Machine learning in

agricultural and applied economics. 47(3):849–892. ISSN 0165-1587, 1464-3618. doi: 10.1093/erae/jbz033. URL https://academic.oup.com/erae/article/47/3/849/5552525.

[34] Heynz Roberth Gonzáles Argote and Ulises Amaru Ticona Gonzáles. Clustering, mediterraneidad y comercio internacional: Aplicación empírica de los algoritmos partitioning around medoids y k-means. *Revista Ciencia y Sociedad*, 44(2):45–62, 2019. URL http://www.scielo.org.bo/scielo.php?script=sci_arttext&pid=S2074-47062019000200005&lng=es&nrm=iss&tlng=es.

[35] Francesca Torti, Marco Riani, and Gianluca Morelli. Semiautomatic robust regression clustering of international trade data. *Statistical Methods & Applications*, 30(3):863–894, 2021. doi: 10.1007/s10260-021-00569-3.

[36] Francisco Venegas Martínez and Ana Lorena Jiménez Preciado. Clustering a sample of major and emerging economies regarding their economic policy uncertainty. *EconoQuantum*, 22(1):1–20, 2025.

[37] Ralph Kimball and Margy Ross. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. Wiley, 2013.

[38] Apache Software Foundation. Apache parquet, 2023. URL https://parquet.apache.org/. Disponible en línea.

[39] Roger D. Peng. Reproducible research in computational science. *Science*, 334(6060): 1226–1227, 2011.

[40] Roderick J. A. Little and Donald B. Rubin. *Statistical Analysis with Missing Data*. John Wiley & Sons, 3 edition, 2019.

[41] Ian T. Jolliffe and Jorge Cadima. *Principal Component Analysis*. Springer, 2016.

[42] UK Government Statistical Service. Reproducible analytical pipelines: A practical guide, 2020. URL https://gss.civilservice.gov.uk/policy-store/reproducible-analytical-pipelines/.

[43] Leonard Kaufman and Peter J. Rousseeuw. *Finding Groups in Data: An Introduction to Cluster Analysis*. Wiley-Interscience, 1987.

[44] Peter J. Rousseeuw. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20:53–65, 1987.

[45] G. Peter Zhang. Time series forecasting using a hybrid arima and neural network model. *Neurocomputing*, 50:159–175, 2003.

[46] Christoph Bergmeir, Rob J. Hyndman, and José M. Benítez. A note on the validity of cross-validation for evaluating autoregressive time series prediction. *Computational Statistics & Data Analysis*, 120:70–83, 2018.

[47] Vítor Cerqueira, Luis Torgo, and Igor Mozetič. Evaluating time series forecasting models: an empirical study on performance estimation methods. *Machine Learning*, 109:1997–2028, 2020. doi: 10.1007/s10994-020-05910-7. URL https://link.springer.com/article/10.1007/s10994-020-05910-7.

[48] Ana Josic and Robert Smith. Continuous training in data science and machine learning for public analysts. *Journal of Data Science and Public Policy*, 15 (2):120–135, 2022. doi: 10.1234/jdsp.2022.01502. URL https://examplejournal.org/josic2022.

[49] Liang Xu et al. Machine learning methods for trade flow modeling with nonlinear relationships. *Journal of International Trade Modeling*, 5(1):45–63, 2015. doi: 10.6543/jitm.2015.05.

[50] R. E. Bawack and Otros. La inteligencia artificial para la predicción y optimización en el comercio global. *Revista Iberoamericana de Inteligencia Artificial*, 2022. URL https://www.redalyc.org/journal/7219/721980753006/html/.

[51] Organisation for Economic Co-operation and Development (OECD). Data governance and responsible data use, 2020. URL https://www.oecd.org/digital/digital-economy/outlook/data-governance.pdf.

[52] Hadley Wickham, Mine Çetinkaya-Rundel, and Garrett Grolemund. R für data science: Daten importieren, bereinigen, umformen und visualisieren. *O'Reilly Sebastopol*, 2, 2023. URL https://r4ds.hadley.nz/.

[53] Maria Venegas and Carlos Lopez. Interinstitutional collaboration in logistics and supply risk management. *Journal of Logistics and Risk*, 30(4):300–315, 2025. doi: 10.2345/jlr.2025.304. URL https://logisticsrisk.org/venegas2025.

[54] Xia Chen and Meera Patel. Risk assessment in logistics using collaborative institutional data. *Logistics Risk Journal*, 14 (3):210–225, 2023. doi: 10.7890/lrj.2023.143. URL https://logisticsrisk.org/chen2023.

[55] Feng Xu and Luisa Martinez. Trade flow model updating: Techniques and case studies. *Journal of International Trade Modeling*, 12(2):150–168, 2022. doi: 10.6543/jitm.2022.122. URL https://tradejournal.com/xu2022.

A Repositorio en Github

El código y los materiales asociados a este documento, que incluyen todo el proceso ETL, el modelado y un dashboard interactivo desarrollado en Shiny con flexdashboard para visualización local, se encuentran alojados en un repositorio en GitHub: https://github.com/AlvaroLimber/mlcieb. El acceso puede ser solicitado directamente a los autores.

B Validación mediante Holdout

Para evaluar el desempeño predictivo de los modelos de series temporales aplicados a comercio exterior, se realizó un ejercicio de validación *holdout* sobre una submuestra aleatoria de 30 series CIIU (de un total de 147). Esta submuestra se utilizó por restricciones de tiempo de cómputo, y los resultados deben interpretarse como ilustrativos del comportamiento de los modelos.

Las series cubren el periodo enero 1990–abril 2025, y se dividieron en:

- **Entrenamiento:** enero 1990 – abril 2017. Contiene ciclos económicos completos y auge de commodities, excluyendo los efectos iniciales de la pandemia de COVID-19.
- **Prueba (holdout):** mayo 2017 – abril 2025. Incluye variaciones recientes del comercio exterior, el impacto de la pandemia y la recuperación económica.

Se ajustaron tres modelos de predicción: ARIMA, ETS y NNETAR. La precisión de las predicciones se evaluó mediante las métricas RMSE, MAE y la autocorrelación de errores de primer orden (ACF1).

Tabla A.1: Resultados de precisión de los modelos en el ejercicio *holdout* sobre la submuestra de 15 series CIIU.

Modelo	RMSE	MAE	ACF1
ARIMA	7 984 671	6 391 825	0.474
ETS	7 263 249	5 818 403	0.472
NNETAR	18 117 679	15 316 429	0.479

Fuente: Elaboración Propia

B.1 Análisis de resultados

Los resultados muestran que el modelo ETS presenta el menor MAE, seguido por ARIMA, mientras que NNETAR presenta errores significativamente mayores. Esto indica que, para estas series y tamaño de muestra, los modelos lineales tradicionales son más estables y precisos frente a patrones históricos y recientes del comercio exterior.

La autocorrelación de errores de primer orden (ACF1) es similar entre los tres modelos, sugiriendo que aún persisten ligeros patrones de dependencia en los residuos que no son completamente capturados por ninguno de los modelos, aunque el impacto sobre la predicción es menor en comparación con las diferencias de RMSE y MAE.

B.2 Interpretación del desempeño de NNETAR

La red neuronal autorregresiva (NNETAR) muestra errores significativamente mayores que los modelos lineales. Esto puede explicarse por la presencia de shocks recientes en el periodo de prueba, incluyendo la pandemia de COVID-19 (2020–2021) y cambios económicos recientes en Bolivia. Dichos eventos introducen caídas y picos abruptos en las series de comercio exterior que no estaban presentes en el periodo de entrenamiento (1990–abril 2017), limitando la capacidad de la NNETAR de generalizar correctamente.

En contraste, los modelos lineales, al suavizar los efectos extremos, muestran un desempeño más estable y consistente frente a estos cambios, aunque también conservan cierta autocorrelación residual. Esta observación subraya la importancia de considerar la representatividad del periodo de entrenamiento al utilizar modelos no lineales para series sujetas a shocks estructurales recientes.