

**UNIVERSIDADE FEDERAL DA FRONTEIRA SUL  
CAMPUS CHAPECÓ  
CURSO DE CIÊNCIA DA COMPUTAÇÃO**

**LOUDE DJEMA SIME**

**SISTEMA DE APOIO À DECISÃO PARA  
EXPORTAÇÃO DE ALIMENTOS: RECOMENDAÇÃO  
DE MERCADOS LUSÓFONOS AFRICANOS PARA  
UMA EMPRESA CATARINENSE**

**CHAPECÓ  
2026**

**LOUDE DJEMA SIME**

**SISTEMA DE APOIO À DECISÃO PARA  
EXPORTAÇÃO DE ALIMENTOS: RECOMENDAÇÃO  
DE MERCADOS LUSÓFONOS AFRICANOS PARA  
UMA EMPRESA CATARINENSE**

Trabalho de Conclusão de Curso apresentado ao  
Curso de Ciência da Computação da Universidade  
Federal da Fronteira Sul (UFFS), como requisito  
para obtenção do título de Bacharel em Ciência  
da Computação.

Orientador: Prof. Dr. Denio Duarte  
Co-Orientador: Prof. Dra. Inocência Boita Dalbosco

**CHAPECÓ  
2026**

## **DEDICATÓRIA**

Dedico este trabalho a meus pais.

“Cela semble toujours impossible jusqu’à ce  
que ce soit fait.”  
(Nelson Mandela)

## RESUMO

O comércio exterior brasileiro tem passado por crescente diversificação de mercados, e os Países Africanos de Língua Oficial Portuguesa (PALOP) representam uma oportunidade estratégica para empresas do setor alimentício, em razão da proximidade linguística e cultural com o Brasil. Entretanto, a identificação de mercados de exportação adequados ao perfil de uma empresa específica permanece um desafio, e as ferramentas de inteligência comercial disponíveis operam apenas em nível nacional e setorial, sem considerar o portfólio individual de cada empresa. Este trabalho propõe um sistema de apoio à decisão para recomendação de mercados de exportação, voltado a uma empresa do setor alimentício do Oeste de Santa Catarina sem histórico de exportação para o bloco PALOP. O sistema proposto é híbrido, combinando o modelo gravitacional de comércio internacional, filtragem colaborativa e filtragem baseada em conteúdo, e utiliza dados públicos do ComexStat, do Banco Mundial e do PNUD, complementados por informações internas da empresa. As recomendações de pares produto–mercado serão avaliadas por meio das métricas de Precisão, Recall e F1-Score, sob protocolo de validação temporal. Espera-se que o sistema forneça à empresa-alvo recomendações personalizadas de mercados lusófonos africanos com maior potencial, apoiando sua estratégia de expansão internacional. A principal contribuição é a aplicação de técnicas de sistemas de recomendação a dados oficiais do comércio exterior brasileiro, abordagem ainda pouco explorada na literatura nacional.

**Palavras-Chave:** Sistemas de recomendacao. Comercio exterior. Modelo gravitacional. Exportacao de alimentos. PALOP.

## LISTA DE FIGURAS

|     |                                                                      |    |
|-----|----------------------------------------------------------------------|----|
| 2.1 | Em vermelho, a localização dos PALOP no continente africano. . . . . | 17 |
| 2.2 | Interface de consulta detalhada da plataforma ComexStat. . . . .     | 20 |
| 5.1 | Pipeline do sistema de recomendação proposto. . . . .                | 36 |

## LISTA DE TABELAS

|     |                                                                                        |    |
|-----|----------------------------------------------------------------------------------------|----|
| 2.1 | Critérios de seleção de mercados e sua operacionalização no sistema proposto . . . . . | 15 |
| 2.2 | Indicadores socioeconômicos dos PALOP e do Brasil . . . . .                            | 18 |
| 4.1 | Comparação das principais características dos trabalhos relacionados                   | 32 |
| 5.1 | Distância geodésica entre o Porto de Itajaí e os portos dos países do PALOP . . . . .  | 38 |
| 6.1 | Cronograma de atividades para o desenvolvimento do TCC I e TCC II.                     | 42 |

# SUMÁRIO

|          |                                                    |           |
|----------|----------------------------------------------------|-----------|
| <b>1</b> | <b>INTRODUÇÃO</b>                                  | <b>9</b>  |
| 1.1      | PROBLEMA DE PESQUISA                               | 9         |
| 1.2      | OBJETIVOS                                          | 9         |
| 1.2.1    | OBJETIVO GERAL                                     | 9         |
| 1.2.2    | OBJETIVOS ESPECÍFICOS                              | 10        |
| 1.3      | JUSTIFICATIVA                                      | 10        |
| 1.4      | ESTRUTURA DO TRABALHO                              | 11        |
| <b>2</b> | <b>EXPORTAÇÃO</b>                                  | <b>12</b> |
| 2.1      | EXPORTAÇÃO: CONTEXTO HISTÓRICO E EVOLUÇÃO          | 12        |
| 2.2      | CARACTERIZAÇÃO DA EMPRESA-ALVO                     | 13        |
| 2.3      | SELEÇÃO DE MERCADOS INTERNACIONAIS                 | 14        |
| 2.4      | INTELIGÊNCIA COMERCIAL INTERNACIONAL               | 15        |
| 2.5      | MODELO GRAVITACIONAL DE COMÉRCIO INTERNACIONAL     | 16        |
| 2.6      | MERCADOS LUSÓFONOS NO CONTINENTE AFRICANO          | 17        |
| 2.7      | ECOSSISTEMA COMEXSTAT E A DISPONIBILIDADE DE DADOS | 18        |
| <b>3</b> | <b>SISTEMAS DE RECOMENDAÇÃO</b>                    | <b>21</b> |
| 3.1      | DEFINIÇÃO E HISTÓRICO                              | 21        |
| 3.2      | COMPONENTES E FUNCIONAMENTO                        | 22        |
| 3.3      | MÉTODOS DE GERAÇÃO DE RECOMENDAÇÕES                | 22        |
| 3.3.1    | FILTRAGEM COLABORATIVA                             | 23        |
| 3.3.2    | FILTRAGEM BASEADA EM CONTEÚDO                      | 24        |
| 3.3.3    | SISTEMAS HÍBRIDOS                                  | 25        |
| 3.3.4    | RECOMENDAÇÃO POR DESCOBERTA DE CONHECIMENTO        | 25        |
| 3.4      | MÉTRICAS DE AVALIAÇÃO                              | 26        |
| <b>4</b> | <b>TRABALHOS RELACIONADOS</b>                      | <b>28</b> |
| <b>5</b> | <b>METODOLOGIA</b>                                 | <b>34</b> |
| 5.1      | COLETA DE DADOS                                    | 34        |
| 5.2      | PRÉ-PROCESSAMENTO DOS DADOS                        | 35        |

|          |                                                      |           |
|----------|------------------------------------------------------|-----------|
| 5.3      | MODELO GRAVITACIONAL .....                           | 36        |
| 5.4      | SISTEMA DE RECOMENDAÇÃO UTILIZADO .....              | 38        |
| 5.5      | FERRAMENTAS, TECNOLOGIAS E MÉTRICAS UTILIZADAS ..... | 40        |
| 5.6      | PROTOCOLO DE AVALIAÇÃO .....                         | 41        |
| <b>6</b> | <b>CRONOGRAMA .....</b>                              | <b>42</b> |
|          | <b>REFERÊNCIAS .....</b>                             | <b>43</b> |

## 1. INTRODUÇÃO

O comércio exterior brasileiro tem passado por um processo crescente de diversificação, impulsionado pela busca de novos mercados e pela redução da dependência de destinos tradicionais. Nesse contexto, os países africanos de língua oficial portuguesa coletivamente designados como PALOP representam uma oportunidade estratégica para empresas brasileiras do setor alimentício, em razão da proximidade linguística, dos laços históricos e culturais compartilhados e do crescimento econômico registrado na região nas últimas décadas (Comunidade dos Países de Língua Portuguesa, 2022).

Apesar desse potencial, a identificação de mercados de exportação adequados ao perfil de uma empresa específica ainda é um desafio complexo, que envolve a análise simultânea de múltiplas variáveis econômicas, geográficas e setoriais. Ferramentas como o Mapa de Oportunidades da ApexBrasil (ApexBrasil, 2025) oferecem painéis de inteligência comercial em nível nacional e setorial, mas não consideram o histórico específico de exportação de uma empresa individual nem as características particulares de seu portfólio de produtos.

### 1.1 Problema de Pesquisa

Diante desse cenário, este trabalho parte da seguinte questão de pesquisa: *como recomendar, de forma automatizada e baseada em dados, os mercados lusófonos africanos com maior potencial para a expansão das exportações de uma empresa alimentícia catarinense já consolidada na América Latina?*

### 1.2 Objetivos

#### 1.2.1 Objetivo Geral

Desenvolver um sistema de apoio à decisão para exportação de alimentos, baseado em técnicas de sistemas de recomendação e modelo gravitacional, capaz de recomendar, para cada produto do portfólio de uma empresa do setor alimentí-

cio do Oeste de Santa Catarina, os mercados dos países africanos de língua oficial portuguesa (PALOP) com maior potencial.

### 1.2.2 Objetivos Específicos

1. Coletar e processar dados históricos de exportação da plataforma ComexStat e indicadores macroeconômicos do Banco Mundial e do PNUD referentes aos países do PALOP;
2. Aplicar o modelo gravitacional adaptado de Tinbergen (1962) para calcular o score de potencial de mercado de cada país do PALOP;
3. Implementar um sistema de recomendação híbrido que combina o modelo gravitacional, a filtragem colaborativa e a filtragem baseada em conteúdo para identificar, para cada produto do portfólio, os mercados do PALOP com maior potencial para a empresa-alvo;
4. Avaliar a qualidade das recomendações geradas por meio das métricas de Precisão, Recall e F1Score.

## 1.3 Justificativa

A relevância deste trabalho justifica-se por três fatores convergentes. Primeiro, do ponto de vista prático, a empresa alvo possui interesse estratégico em diversificar seus destinos de exportação para além da América Latina, e a ausência de ferramentas personalizadas de inteligência comercial dificulta essa decisão. Segundo, do ponto de vista acadêmico, a revisão da literatura não identificou trabalhos nacionais que combinem sistemas de recomendação com dados do ComexStat para apoio à decisão de exportação personalizada, configurando uma lacuna que este estudo se propõe a preencher. Terceiro, do ponto de vista tecnológico, os dados necessários para o desenvolvimento do sistema são públicos e gratuitos ComexStat, Banco Mundial e PNUD, o que torna a solução proposta acessível.

## **1.4 Estrutura do Trabalho**

Este trabalho está organizado em cinco capítulos. O Capítulo 2 apresenta o contexto do comércio exterior brasileiro, a caracterização da empresa-alvo, seleção de internacional, os mercados lusófonos africanos como destino estratégico e a plataforma ComexStat como principal fonte de dados. O Capítulo 3 apresenta os fundamentos teóricos dos sistemas de recomendação, incluindo as técnicas de filtragem colaborativa, filtragem baseada em conteúdo e sistemas híbridos. O Capítulo 4 discute os trabalhos relacionados. O Capítulo 5 descreve os procedimentos metodológicos adotados, incluindo a coleta de dados, o pré-processamento, o modelo gravitacional e o sistema de recomendação proposto. Por fim, o Capítulo 6 apresenta o cronograma deste trabalho.

## 2. EXPORTAÇÃO

Este capítulo apresenta os principais conceitos sobre o comércio exterior brasileiro, elementos essenciais para compreender o ambiente no qual o sistema de recomendação proposto se insere. Inicia-se com um breve histórico da exportação brasileira, seguido pela caracterização da empresa-alvo do estudo, pelos fatores de seleção de mercados internacionais, por uma breve ponte entre a inteligência comercial e a ciência da computação, uso do modelo gravitacional na estimativa do potencial de mercado, pela descrição do mercado lusófono africano como destino estratégico e, por fim, pela apresentação da plataforma ComexStat <sup>1</sup> como principal fonte de dados.

### 2.1 Exportação: Contexto Histórico e Evolução

A exportação pode ser definida como o processo de venda e envio de mercadorias ou serviços para outro país, constituindo um dos pilares do desenvolvimento da economia nacional. Segundo Prado Júnior (2011), o sentido da colonização brasileira foi estruturado para atender prioritariamente ao mercado externo. Esse processo, iniciado em 1500 com o ciclo do pau-brasil e a relação exclusiva com Portugal, consolidou-se em 1808 com a Abertura dos Portos às Nações Amigas, que permitiu ao Brasil expandir suas relações comerciais para além do pacto colonial.

A trajetória da exportação brasileira foi marcada por profundas transformações ao longo dos séculos, evoluindo de uma atividade baseada na simples extração e troca de mercadorias para uma operação estratégica, apoiada em inteligência comercial e em decisões orientadas por dados. Segundo Minervini (2021), essa evolução não representa apenas um aumento de volume comercial, mas configura-se como um mecanismo de aceleração do desenvolvimento nacional.

Nessa perspectiva, Kaldor (1966) argumenta que a expansão das exportações industriais gera um círculo virtuoso de crescimento, pois impõe à indústria a necessidade de elevar seus padrões de produtividade e inovação para competir no mercado global. Complementando essa visão, Thirlwall (1979) demonstra que o crescimento econômico de longo prazo de um país é condicionado pela sua capacidade de expandir as exportações em ritmo suficiente para equilibrar a balança de pagamentos argumento que reforça a centralidade da atividade exportadora na agenda de desenvolvimento nacional.

---

<sup>1</sup><comexstat.mdic.gov.br/pt/home>

Nas últimas décadas, a pauta de exportação brasileira passou por um processo de reprimarização, ou seja, os produtos básicos commodities com baixo grau de processamento voltaram a predominar sobre os manufaturados. Conforme dados do Ministério do Desenvolvimento, Indústria, Comércio e Serviços (2024), esses produtos básicos respondem hoje pela maior parte das exportações do país. O setor de alimentos, no entanto, mantém peso expressivo e em expansão na pauta nacional. Para uma empresa desse setor, como a estudada neste trabalho, o principal desafio não está em modificar seus produtos, mas em descobrir para quais países exportá-los. É nesse ponto que se torna útil um sistema de apoio à decisão capaz de indicar novos mercados a partir da análise de dados.

## 2.2 Caracterização da Empresa-Alvo

O estudo de caso tem como objeto uma indústria do setor alimentício situada no polo agroindustrial do Oeste de Santa Catarina, com mais de três décadas de atuação no mercado. A empresa possui mais de 650 colaboradores diretos e uma área construída superior a 35.000 m<sup>2</sup>, com capacidade produtiva mensal de 7.500 toneladas, o que a posiciona entre as mais relevantes do segmento em âmbito regional. Com presença consolidada no mercado nacional, onde figura entre as marcas líderes em suas principais linhas, e atuação no mercado internacional há mais de dez anos, concentrada principalmente na América Latina, a empresa destaca-se pela qualidade de seus processos industriais e pela diversidade de seu portfólio, que reúne mais de 380 itens.

A estrutura produtiva é voltada para a fabricação de produtos alimentícios industrializados, como misturas para bolo, sobremesas e gelatinas, achocolatados, refrescos, confeitos e condimentos, atendendo tanto o setor varejista quanto o segmento de *food service*. Conforme o paradigma eclético de Dunning (1980), a internacionalização de empresas com esse porte é favorecida por suas vantagens de propriedade e de localização, que sustentam sua competitividade nos mercados de destino.

A escolha desta empresa como objeto de estudo justifica-se por três fatores convergentes: (i) sua maturidade operacional no mercado externo, que assegura a existência de um histórico consolidado de exportações; (ii) seu portfólio de produtos com potencial de adaptação a novos mercados; e (iii) o interesse estratégico da organização em diversificar seus destinos de exportação para além da América Latina, cenário que cria a demanda pelo sistema de recomendação proposto neste trabalho.

## 2.3 Seleção de Mercados Internacionais

A seleção de mercados internacionais é uma das decisões mais importantes no processo de internacionalização de empresas, pois determina para onde os esforços comerciais serão direcionados e quais riscos a organização estará disposta a assumir (HOLLESEN, 2020).

Cavusgil (1985) defende que essa escolha deve partir da avaliação do potencial de mercado considerando indicadores como tamanho da população, renda per capita e crescimento econômico seguida da análise das barreiras de acesso, como tarifas, regulações e distância cultural. O objetivo é concentrar esforços nos destinos com maior probabilidade de sucesso, descartando aqueles com barreiras intransponíveis ou demanda insuficiente.

Root (1994) propõe um processo estruturado em três etapas: primeiro, filtrar os países com base em barreiras geográficas, políticas, econômicas ou culturais; segundo, avaliar o tamanho do mercado e a demanda para o produto da empresa; e terceiro, estimar a participação de mercado que a empresa pode conquistar, levando em conta produto, preço, concorrência e marketing.

Já Hollensen (2020) classifica os mercados pelo nível de esforço e comprometimento exigido. Países com alto potencial de crescimento demandam pesquisa aprofundada e estratégia de longo prazo; países com risco político ou econômico elevado não justificam compromissos duradouros; e mercados de risco muito elevado devem ser abordados com esforço mínimo e cautela.

Esses critérios fundamentam a escolha dos Países Africanos de Língua Oficial Portuguesa (PALOP) como destinos estratégicos neste trabalho. Os cinco países apresentam potencial relevante de mercado com crescimento do Produto Interno Bruto (PIB) e populações em expansão e compartilham com o Brasil a língua portuguesa, reduzindo significativamente a distância cultural (JOHANSON; VAHLNE, 1977). O risco-país, medido por indicadores de estabilidade política e crescimento econômico (World Bank, 2024a), será incorporado ao sistema como fator de ajuste do score final, penalizando mercados com maior instabilidade.

A Tabela 2.1 apresenta os critérios de seleção de mercados internacionais propostos por Cavusgil (1985), Root (1994) e Hollensen (2020), e como cada critério é operacionalizado no sistema de recomendação proposto neste trabalho.

Tabela 2.1 – Critérios de seleção de mercados e sua operacionalização no sistema proposto

| <b>Critério</b>        | <b>Operacionalização</b>                         |
|------------------------|--------------------------------------------------|
| Potencial de mercado   | Score gravitacional (PIB, população e distância) |
| Renda per capita       | PIB per capita (PPP)                             |
| Crescimento econômico  | Taxa de crescimento do PIB                       |
| Distância cultural     | Língua portuguesa comum                          |
| Desenvolvimento humano | IDH e taxa de alfabetização                      |
| Risco-país             | Estabilidade política                            |

Fonte: Adaptado de Cavusgil (1985), Root (1994) e Hollensen (2020).

## 2.4 Inteligência Comercial Internacional

A inteligência comercial internacional pode ser definida como o processo sistemático de coleta, análise e aplicação de informações sobre mercados externos, com o objetivo de apoiar decisões estratégicas de exportação e internacionalização de empresas (MINERVINI, 2021). Trata-se de transformar dados brutos de comércio exterior em conhecimento acionável, permitindo que empresas identifiquem oportunidades, avaliem riscos e direcionem seus esforços para os mercados com maior potencial.

No contexto brasileiro, a ApexBrasil define inteligência comercial como a coleta e análise de informações essenciais para que empresas brasileiras identifiquem e conheçam os mercados de interesse para a exportação de seus produtos e serviços (ApexBrasil, 2025). Para isso, a agência utiliza bases de dados confiáveis que produzem informações sobre macroeconomia, setores econômicos, comércio exterior e acesso a mercados. Essa abordagem converge diretamente com a proposta deste trabalho.

O sistema de recomendação proposto neste trabalho insere-se nesse conceito de inteligência comercial internacional, aplicando-o à Ciência da Computação. Ao combinar dados históricos de exportação do ComexStat com indicadores macroeconômicos do Banco Mundial e do Programa das Nações Unidas para o Desenvolvimento (PNUD), o sistema automatiza o processo de análise de mercados e gera recomendações personalizadas para a empresa-alvo, funcionando como uma ferramenta computacional de inteligência comercial voltada especificamente para o setor alimentício catarinense e os mercados lusófonos africanos.

## 2.5 Modelo Gravitacional de Comércio Internacional

O modelo gravitacional de comércio internacional é uma das ferramentas analíticas mais consolidadas na literatura econômica para estimar o potencial de fluxos comerciais entre países. Proposto originalmente por Tinbergen (1962), inspira-se na Lei da Gravitação Universal de Newton e postula que o volume de comércio entre dois países é diretamente proporcional ao produto de suas massas econômicas, representadas pelo Produto Interno Bruto (PIB), e inversamente proporcional à distância geográfica entre eles.

A intuição econômica é direta: países com maior PIB tendem a exportar e importar mais, por disporem de maior capacidade produtiva e de consumo; ao mesmo tempo, países geograficamente próximos comerciam mais entre si, em razão dos menores custos de transporte e logística (TINBERGEN, 1962). Ao longo das décadas, pesquisadores incorporaram variáveis adicionais ao modelo original, como população, idioma comum, acordos comerciais e fronteiras compartilhadas, ampliando sua capacidade explicativa sem descaracterizar sua essência gravitacional.

Na literatura recente que aplica aprendizado de máquina ao comércio internacional, o modelo gravitacional tem sido amplamente utilizado como fonte de variáveis preditoras. Rincon-Yanez et al. (2023) incorporaram o score gravitacional como componente de um grafo de conhecimento para previsão de fluxos comerciais, obtendo ganhos expressivos de acurácia. Batarseh, Ghassem-Aghaee e Chong (2019), por sua vez, identificaram a distância e o PIB como as variáveis de maior influência na previsão do comércio de commodities agrícolas, o que reforça a relevância dessas dimensões para o setor alimentício.

Neste trabalho, o modelo gravitacional será utilizado para calcular um score de potencial de mercado para cada um dos PALOP, combinando PIB, população e distância geográfica em um único indicador comparável. Essa abordagem permite quantificar objetivamente o potencial de cada mercado mesmo na ausência de histórico expressivo de exportações, situação comum entre os PALOP, complementando as técnicas de filtragem colaborativa e por conteúdo do sistema de recomendação proposto. A formulação adaptada será detalhada na Seção 5.3.

Cabe ressaltar que a decisão exportadora não depende apenas do potencial de demanda: fatores como risco cambial, estabilidade política e ambiente regulatório também influenciam a viabilidade das operações (ROOT, 1994). Esses fatores serão incorporados ao sistema de recomendação como variáveis de ajuste do score final, conforme detalhado na Seção 5.4.

## 2.6 Mercados Lusófonos no Continente Africano

A escolha dos Países Africanos de Língua Oficial Portuguesa (PALOP), ou seja, Angola, Moçambique, Cabo Verde, Guiné-Bissau e São Tomé e Príncipe como foco deste estudo apoia-se em dois conjuntos de fatores complementares: a proximidade cultural com o Brasil e o potencial econômico desses mercados. A Figura 2.1 apresenta a localização dos cinco países no continente africano.




Figura 2.1 – Em vermelho, a localização dos PALOP no continente africano.

Fonte: CPLP (2022).

No plano cultural, os Países Africanos de Língua Oficial Portuguesa (PALOP) compartilham com o Brasil o idioma português e laços históricos que se refletem nos hábitos de consumo alimentar. De acordo com o modelo de internacionalização de Johanson e Vahlne (1977), as empresas tendem a expandir-se primeiro para mercados culturalmente próximos, nos quais a incerteza e os custos de adaptação são menores, vantagem que o Brasil detém frente a concorrentes de outras origens (CAVUSGIL, 1985).

No plano econômico, os Países Africanos de Língua Oficial Portuguesa (PALOP) combinam urbanização acelerada, expansão da classe média urbana e demanda crescente por alimentos industrializados (World Bank, 2024a). Em 2024, respectivamente Angola e Moçambique, os dois países mais populosos, cresceram 4,4% e 2,2%, enquanto economias menores, como Cabo Verde e Guiné-Bissau, avançaram 7,2% e 4,2% (World Bank, 2024a). O adensamento urbano de centros como Luanda e Maputo, capitais de Angola e Moçambique, respectivamente amplia a procura por produtos de fácil preparo, voltados aos setores de *food service* e varejo.

A cooperação institucional no âmbito da Comunidade dos Países de Língua Portuguesa (CPLP) favorece o relacionamento econômico e empresarial entre os países, embora as condições tarifárias dependam das regras comerciais específicas de cada mercado (Comunidade dos Países de Língua Portuguesa, 2022).

A Tabela 2.2 reúne os principais indicadores socioeconômicos dos PALOP e do Brasil.

**Tabela 2.2 – Indicadores socioeconômicos dos PALOP e do Brasil**

| <b>Indicador</b>                | <b>Angola</b> | <b>Moçambique</b> | <b>Cabo Verde</b> | <b>Guiné-Bissau</b> | <b>S. Tomé e Príncipe</b> | <b>Brasil</b> |
|---------------------------------|---------------|-------------------|-------------------|---------------------|---------------------------|---------------|
| População (milhões, 2024)       | 37,9          | 34,6              | 0,5               | 2,2                 | 0,2                       | 212,0         |
| PIB per capita (USD, 2024)      | 2.666         | 657               | 5.192             | 1.008               | 3.491                     | 10.311        |
| PIB per capita PPP (USD, 2024)  | 10.119        | 1.705             | 11.195            | 3.119               | 6.242                     | 22.338        |
| IDH (2023)                      | 0,616         | 0,493             | 0,668             | 0,514               | 0,637                     | 0,786         |
| Nível de desenvolvimento humano | Médio         | Baixo             | Médio             | Baixo               | Médio                     | Alto          |
| Cresc. PIB (% , 2024)           | 4,4           | 2,2               | 7,2               | 4,2                 | 1,1                       | 3,4           |

Fonte: World Bank (2024); PNUD (2025).

Os dados evidenciam contrastes relevantes entre os mercados. Cabo Verde apresenta o maior PIB per capita PPP (USD 11.195) e o maior IDH entre os PALOP (0,668), ao passo que Angola e Moçambique se destacam pela dimensão populacional. Em termos de dinamismo recente, Cabo Verde e Angola registraram os maiores crescimentos do PIB em 2024 (7,2% e 4,4%), sinalizando economias em expansão. Em conjunto, esses indicadores sustentam a seleção dos PALOP como destinos estratégicos para a empresa-alvo deste estudo.

## **2.7 Ecosistema ComexStat e a Disponibilidade de Dados**

Lançado em 2018 como sucessor do sistema AliceWeb, o ComexStat constitui-se como a ferramenta oficial do Governo Federal para a disseminação de estatísticas do comércio exterior brasileiro. Segundo Ministério do Desenvolvimento, Indústria, Comércio e Serviços (2024), o sistema extrai dados mensalmente do Portal Único

de Comércio Exterior, baseando-se diretamente nas declarações de exportadores e importadores registradas junto à Receita Federal.

Para os fins deste trabalho, as principais variáveis extraídas da plataforma são: (i) o código NCM, que identifica a categoria do produto exportado; (ii) o país de destino da mercadoria; (iii) o valor FOB (*Free on Board*) em dólares americanos; (iv) a quantidade em quilogramas líquidos; e (v) a série temporal mensal das operações, abrangendo o período de 2014 a 2024.

A Figura 2.2 apresenta a interface de consulta detalhada da plataforma Co-mexStat, evidenciando como os parâmetros de pesquisa descritos anteriormente se dispõem para a manipulação do usuário.

Essa estrutura visual e lógica viabiliza o isolamento rigoroso das séries históricas de exportação necessárias para a pesquisa. Crucialmente para o *pipeline* de engenharia de dados deste sistema de recomendação, a interface dispõe de um mecanismo de exportação direta das consultas refinadas em arquivos de texto estruturado delimitado (formato CSV), que posteriormente alimentará a matriz de entrada dos algoritmos de recomendação.

19/05/2026, 00:29

Comex Stat - Dados Gerais

PT

Dados Gerais

Estão disponíveis dados mensais de exportação e importação, de 1997 ao ano atual. Este módulo apresenta os dados mais detalhados possíveis, possibilitando filtros e detalhamentos por NCM, países de destino e origem, UF, via de transporte e URF, além de classificações com grupos de produtos e blocos de países.

Fluxo

Exportação

Importação

Exportação e Importação

Atualizado em 07/05/2026. Dados até 04/2026

Periodo

Ano inicial

2026

Ano final

2026

A seleção de meses será aplicada para todos os anos selecionados acima.

Mês inicial

Janeiro

Mês final

Dezembro

Detalhar por mês

Filtros

Selecione os filtros da consulta

Detalhamento

Selecione as colunas que serão exibidas no resultado

Valores

Valor US\$ FOB

Quilograma Líquido

Voltar

Consultar

Limpar

Figura 2.2 – Interface de consulta detalhada da plataforma ComexStat.  
Fonte: MDIC (2026).

### 3. SISTEMAS DE RECOMENDAÇÃO

Com o avanço das tecnologias de informação e comunicação, o volume de dados disponíveis cresceu exponencialmente, tornando cada vez mais difícil identificar, entre tantas opções, aquelas verdadeiramente relevantes para cada necessidade. Nesse contexto, os sistemas de recomendação surgem como ferramentas computacionais para filtrar grandes volumes de informação e apresentar sugestões personalizadas aos usuários (MOTTA et al., 2011).

Este capítulo apresenta os conceitos fundamentais de sistemas de recomendação, estruturado em quatro seções: definição e histórico, componentes e funcionamento, métodos de geração de recomendações e métricas de avaliação.

#### 3.1 Definição e Histórico

Sistemas de recomendação são filtros de informação que apresentam itens (como páginas web, filmes, músicas, livros ou lojas) provavelmente do interesse do usuário (MOTTA et al., 2011). Seu princípio fundamental baseia-se na premissa de que o que é relevante para um indivíduo também pode ser relevante para alguém com interesses similares (MOTTA et al., 2011).

De forma mais precisa, Adomavicius e Tuzhilin (2005) definem o problema central dos sistemas de recomendação como a estimação da utilidade de itens ainda não avaliados por um usuário, com o objetivo de recomendar aqueles de maior utilidade estimada. Formalmente, sejam  $C$  o conjunto de usuários,  $S$  o conjunto de itens e  $u : C \times S \rightarrow \mathbb{R}$  a função de utilidade que mede a relevância de um item  $s$  para um usuário  $c$ . O sistema busca, para cada usuário  $c \in C$ , o item  $s'_c \in S$  que maximiza essa utilidade, conforme a Equação 3.1:

$$\forall c \in C, \quad s'_c = \arg \max_{s \in S} u(c, s) \quad (3.1)$$

O desafio está no fato de que  $u$  geralmente não está definida para todo o espaço  $C \times S$ , mas apenas para os itens já avaliados; cabe ao sistema estimar os valores desconhecidos e produzir recomendações a partir dessas estimativas (ADOMAVICIUS; TUZHILIN, 2005).

A área consolidou-se na década de 1990. Entre os trabalhos pioneiros estão o RINGO (SHARDANAND; MAES, 1995), que recomendava músicas a partir de perfis

de usuários, e o GroupLens (RESNICK et al., 1994), que propôs uma arquitetura de filtragem colaborativa para notícias e mais tarde deu origem ao MovieLens (MOTTA et al., 2011). Em seguida, empresas como Amazon e Netflix passaram a incorporar sistemas de recomendação em seus produtos, consolidando a área como campo de grande relevância prática.

De acordo com Adomavicius e Tuzhilin (2005), os sistemas de recomendação são classificados em três grandes categorias: baseados em conteúdo, colaborativos e híbridos. Essa taxonomia orienta a estrutura das seções seguintes.

### 3.2 Componentes e Funcionamento

Segundo Motta et al. (2011), os principais componentes de um sistema de recomendação são o **cliente** e o **produto**. O produto é um recurso de natureza variada (um conteúdo, um arquivo, uma informação, uma pessoa ou um objeto), e a recomendação é uma função que mapeia os interesses do cliente para um ou mais produtos, avaliando a utilidade de cada produto geralmente a partir da similaridade entre perfis de usuários.

Os dados que alimentam o sistema têm duas origens principais: as informações do próprio consumidor-alvo e os dados gerados pela comunidade de usuários (MOTTA et al., 2011). As informações do cliente podem ser obtidas de forma explícita (avaliações e preferências declaradas) ou implícita (comportamento de navegação, histórico de compras e consultas anteriores), enquanto os dados da comunidade, como listas dos mais vendidos ou mais visitados, capturam padrões coletivos sem depender de avaliações individuais detalhadas.

Quanto à saída, o sistema pode apresentar listas dos itens mais relevantes ou sugestões proativas a um cliente específico; quanto à personalização, as recomendações variam de visões agregadas do comportamento coletivo (como a lista dos mais vendidos) a recomendações persistentes, construídas a partir do comportamento individual do usuário ao longo do tempo (MOTTA et al., 2011).

### 3.3 Métodos de Geração de Recomendações

Existem diversas técnicas para a geração de recomendações. Adomavicius e Tuzhilin (2005) as agrupam em três grandes abordagens (baseada em conteúdo,

colaborativa e híbrida), às quais Motta et al. (2011) acrescentam a recomendação por descoberta de conhecimento. Essas técnicas são detalhadas nas subseções a seguir.

### 3.3.1 Filtragem Colaborativa

A filtragem colaborativa é um método que tenta prever o grau de interesse de um cliente em determinados produtos a partir de correlações entre as avaliações feitas por ele e as fornecidas por outros clientes (MOTTA et al., 2011). A hipótese subjacente é que pessoas que avaliaram um conjunto de produtos de maneira semelhante devem continuar avaliando de forma similar produtos ainda não consumidos. Assim, para sugerir um produto a um cliente, utilizam-se os dados de avaliação de usuários cujo comportamento seja similar ao do cliente-alvo (MOTTA et al., 2011).

De acordo com Adomavicius e Tuzhilin (2005), os algoritmos de filtragem colaborativa podem ser agrupados em duas classes: baseados em memória (*memory-based*) e baseados em modelos (*model-based*). Os algoritmos baseados em memória utilizam heurísticas para calcular previsões a partir da coleção completa de avaliações, estimando o valor desconhecido  $r_{c,s}$  como um agregado das avaliações dos  $N$  usuários mais similares ao usuário  $c$  para o item  $s$ , conforme a Equação 3.2:

$$\hat{r}_{c,s} = \text{aggr}_{c' \in \hat{C}} r_{c',s} \quad (3.2)$$

onde  $\hat{C}$  denota o conjunto dos  $N$  usuários mais similares a  $c$  que avaliaram o item  $s$  (ADOMAVICIUS; TUZHILIN, 2005). A abordagem mais comum é a soma ponderada pela similaridade entre usuários, calculada pelo coeficiente de correlação de Pearson ou pela similaridade de cosseno (ADOMAVICIUS; TUZHILIN, 2005).

Motta et al. (2011) detalham o processo em três passos: (i) calcular a similaridade entre os usuários; (ii) selecionar os vizinhos mais próximos; e (iii) prever a avaliação do usuário-alvo para um produto não consumido, conforme a Equação 3.3:

$$P_{u,i} = \bar{r}_u + \frac{\sum_{j=1}^n w_{u,j}(r_{j,i} - \bar{r}_j)}{\sum_{j=1}^n |w_{u,j}|} \quad (3.3)$$

onde  $P_{u,i}$  é a previsão de avaliação do item  $i$  pelo usuário  $u$ ;  $\bar{r}_u$  e  $\bar{r}_j$  são as avaliações médias dos usuários  $u$  e  $j$ ;  $w_{u,j}$  é a similaridade entre eles; e  $r_{j,i}$  é a avaliação do item  $i$  feita pelo usuário  $j$  (MOTTA et al., 2011).

Apesar de amplamente utilizada, a filtragem colaborativa apresenta limitações. O cálculo da matriz de similaridade é custoso e deve ser armazenado para garantir respostas rápidas (MOTTA et al., 2011). Além disso, o método não funciona bem com matrizes esparsas, situação comum em sistemas com muitos itens e poucos dados históricos, e exige que os produtos já tenham sido avaliados por outros usuários, o que impede a recomendação de itens novos (MOTTA et al., 2011; ADOMAVICIUS; TUZHILIN, 2005).

### 3.3.2 Filtragem Baseada em Conteúdo

A filtragem baseada em conteúdo utiliza informações sobre as características dos próprios itens para sugerir produtos semelhantes aos que o usuário demonstrou preferir (MOTTA et al., 2011). Diferentemente da filtragem colaborativa, não depende do comportamento de outros usuários, mas dos atributos descritivos dos itens (ADOMAVICIUS; TUZHILIN, 2005).

Formalmente, Adomavicius e Tuzhilin (2005) definem o perfil de conteúdo de um item  $s$  como  $\text{Content}(s)$ , um conjunto de atributos que o caracteriza, e o perfil do usuário  $c$  como  $\text{ContentBasedProfile}(c)$ , um vetor de pesos que descreve a importância de cada característica para aquele usuário. A função de utilidade é definida pela Equação 3.4:

$$u(c, s) = \text{score}(\text{ContentBasedProfile}(c), \text{Content}(s)) \quad (3.4)$$

O processo é composto de quatro passos: classificar os itens avaliados segundo categorias pré-estabelecidas; calcular a avaliação média por categoria para cada usuário; ordenar os itens por categorias de preferência; e calcular a previsão de avaliação (MOTTA et al., 2011).

Entre as vantagens, Motta et al. (2011) destacam que o método não necessita de dados de outros usuários, recomenda itens novos ou pouco populares, não sofre com a esparsidade e atende usuários de gostos exclusivos, além de fornecer explicações claras com base nas características do conteúdo. Como limitação, as recomendações tendem a ser estáticas e podem sofrer com a *over-specialization*, recomendando apenas itens muito similares aos já conhecidos pelo usuário e reduzindo a diversidade das sugestões (ADOMAVICIUS; TUZHILIN, 2005).

### 3.3.3 Sistemas Híbridos

Os sistemas híbridos combinam abordagens colaborativas e baseadas em conteúdo para superar as limitações individuais de cada técnica. Adomavicius e Tuzhilin (2005) classificam as formas de hibridização em quatro estratégias principais:

1. **Combinação de sistemas separados:** implementam-se separadamente um sistema colaborativo e um baseado em conteúdo, combinando suas previsões por combinação linear de escores ou por votação;
2. **Incorporação de características de conteúdo em modelos colaborativos:** mantêm-se perfis de conteúdo para cada usuário e os utilizam para calcular similaridades, atenuando a esparsidade;
3. **Incorporação de características colaborativas em modelos de conteúdo:** aplicam-se técnicas de redução de dimensionalidade, como a Decomposição em Valores Singulares (SVD), sobre perfis de conteúdo para criar uma visão colaborativa da coleção;
4. **Construção de um modelo unificado:** desenvolvem-se modelos únicos que incorporam simultaneamente características colaborativas e de conteúdo.

Estudos comparativos mostram de forma consistente que sistemas híbridos superam abordagens isoladas em acurácia e cobertura das recomendações (ADOMAVICIUS; TUZHILIN, 2005).

### 3.3.4 Recomendação por Descoberta de Conhecimento

A recomendação por descoberta de conhecimento não utiliza diretamente as avaliações dos usuários, mas a frequência com que determinadas ações ocorrem em conjunto, fundamentando-se em regras de associação oriundas da mineração de dados (MOTTA et al., 2011). Uma regra  $X \rightarrow Y$  possui dois critérios: o **suporte**, frequência com que  $X$  e  $Y$  aparecem juntos na base, e a **confiança**, probabilidade de  $Y$  ocorrer dado que  $X$  ocorreu (MOTTA et al., 2011).

No contexto deste trabalho, essa abordagem permite identificar padrões como *“empresas que exportaram o produto X para Angola também exportaram o produto Y para Moçambique”*, extraíveis diretamente dos dados históricos do ComexStat. Como

limitação, o processamento é custoso e cresce exponencialmente com o número de produtos (MOTTA et al., 2011).

### 3.4 Métricas de Avaliação

A avaliação de sistemas de recomendação é fundamental para mensurar a qualidade das recomendações e comparar abordagens de forma objetiva (ADOMAVICIUS; TUZHILIN, 2005). As métricas são geralmente agrupadas em duas categorias: de acurácia estatística e de suporte à decisão. A escolha entre elas depende da natureza da tarefa: prever o valor de uma avaliação ou ordenar um conjunto de itens segundo sua relevância.

As métricas de acurácia estatística comparam as avaliações estimadas com as reais, sendo adequadas a sistemas que predizem notas explícitas. As mais utilizadas são o Erro Médio Absoluto (*Mean Absolute Error*, MAE) e a Raiz do Erro Quadrático Médio (*Root Mean Squared Error*, RMSE), definidos pelas Equações 3.5 e 3.6:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i| \quad (3.5)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2} \quad (3.6)$$

onde  $\hat{y}_i$  é o valor previsto e  $y_i$  o valor real da  $i$ -ésima instância, com  $n$  o total de instâncias. O RMSE penaliza erros maiores de forma mais severa que o MAE, sendo preferível quando grandes erros de previsão são especialmente indesejáveis (ADOMAVICIUS; TUZHILIN, 2005).

As métricas de suporte à decisão avaliam a qualidade da lista de itens recomendados e derivam da recuperação de informação (ADOMAVICIUS; TUZHILIN, 2005). Como o sistema proposto neste trabalho não estima notas, mas produz uma lista ordenada (*ranking*) de pares produto–mercado, da qual apenas os primeiros itens são apresentados à empresa, são essas as métricas pertinentes à sua avaliação. Por esse motivo, o MAE e o RMSE não são empregados, adotando-se em seu lugar as métricas de suporte à decisão calculadas até uma posição de corte  $k$  (*top-k*).

As três métricas clássicas dessa categoria são a Precisão, o Recall e o F1-Score. A **Precisão@k** mede a proporção de itens relevantes entre os  $k$  primeiros recomendados; o **Recall@k**, a proporção dos itens relevantes que foram recuperados entre os  $k$  primeiros; e o **F1@k** combina ambos em um único valor, útil quando há

desequilíbrio entre os resultados (ADOMAVICIUS; TUZHILIN, 2005). Essas métricas são definidas pelas Equações 3.7, 3.8 e 3.9:

$$\text{Precisão@}k = \frac{|\text{Recomendados}_k \cap \text{Relevantes}|}{k} \quad (3.7)$$

$$\text{Recall@}k = \frac{|\text{Recomendados}_k \cap \text{Relevantes}|}{|\text{Relevantes}|} \quad (3.8)$$

$$\text{F1@}k = \frac{2 \cdot \text{Precisão@}k \cdot \text{Recall@}k}{\text{Precisão@}k + \text{Recall@}k} \quad (3.9)$$

onde  $\text{Recomendados}_k$  é o conjunto dos  $k$  itens no topo do *ranking* e *Relevantes* é o conjunto de itens de fato relevantes.

A definição das métricas apresentada nesta seção é retomada no Capítulo 5, onde se especifica o protocolo de avaliação adotado, incluindo a divisão temporal dos dados e a definição de relevância no domínio de exportação.

## 4. TRABALHOS RELACIONADOS

Este capítulo analisa trabalhos que aplicam técnicas de aprendizado de máquina e sistemas de recomendação ao comércio internacional, com ênfase na previsão de fluxos comerciais e na seleção de mercados de exportação. Ao final, os estudos são comparados com a proposta deste trabalho.

Rincon-Yanez et al. (2023) abordam a previsão de fluxos de comércio internacional, buscando estimar o volume de exportações e identificar relações comerciais entre países. Para isso, combinam bases consolidadas: (*United Nations Commodity Trade Statistics Database*) UN Comtrade, repositório oficial de estatísticas de comércio das Nações Unidas; (*Base pour l'Analyse du Commerce International*) o BACI, versão harmonizada do Comtrade desenvolvida pelo CEPII (*Centre d'Études Prospectives et d'Informations Internationales*) com as inconsistências entre declarações corrigidas; e o CEPII Gravity Dataset, que reúne variáveis econômicas e geográficas como PIB, população e distância bilateral entre países.

A contribuição central do trabalho é a construção de um grafo de conhecimento (*knowledge graph*) que incorpora o modelo gravitacional clássico. Nessa representação, os países são nós e as relações comerciais são arestas ponderadas pela pontuação gravitacional entre pares de países. Sobre esse grafo, aplica-se um algoritmo de agrupamento para categorizar as diferentes forças gravitacionais e, em seguida, o método de *embedding* TransE (*Translating Embeddings*) gera representações vetoriais de baixa dimensionalidade para os países, utilizadas como variáveis de entrada em modelos de árvore de decisão e de redes neurais em grafo.

Os resultados mostram ganhos expressivos em relação aos modelos *baseline*: na tarefa de predição de relações comerciais, a acurácia sobe de cerca de 80% para 92% quando se utilizam as variáveis de *embedding* geradas a partir do grafo gravitacional, em vez das variáveis básicas. Os autores concluem que a integração de grafos de conhecimento com aprendizado de máquina melhora significativamente a enriquecimento do modelo com indicadores adicionais, como transporte e risco-país (RINCON-YANEZ et al., 2023). Para o presente trabalho, esse estudo é relevante por evidenciar que o modelo gravitacional é uma fonte eficaz de variáveis, abordagem aqui adotada na estimativa do potencial de mercado dos Países Africanos de Língua Oficial Portuguesa (PALOP), e por reforçar a inclusão do risco-país como fator de ajuste.

Batarseh, Ghassem-Aghaee e Chong (2019) aplicaram técnicas de aprendizado de máquina à previsão de tendências do comércio internacional de *commodities* agrícolas. Os dados de comércio foram obtidos de sistemas abertos do Departamento de Agricultura dos Estados Unidos (USDA), e os indicadores econômicos, do World

Integrated Trade Solution (WITS), do Banco Mundial, e do portal de dados gravitacionais da Comissão de Comércio Internacional dos Estados Unidos. Foram analisadas sete *commodities* (entre elas trigo, milho, carne bovina e soja), associadas a mais de trinta variáveis econômicas, como PIB, população, distância geográfica entre países e participação em acordos comerciais.

Para a modelagem, os autores combinaram métodos supervisionados e não supervisionados. Compararam diversos algoritmos de previsão, de regressão linear e modelos de séries temporais a técnicas de *boosting*, e empregaram o agrupamento K-Means para classificar os países segundo seu perfil econômico. O objetivo era avaliar qual abordagem oferecia maior capacidade preditiva sobre os fluxos de comércio das *commodities* analisadas, tomando como referência as previsões oficiais publicadas pelo próprio Departamento de Agricultura dos Estados Unidos (USDA).

O LightGBM (*Light Gradient Boosting Machine*) obteve o melhor desempenho, superando com ampla margem a acurácia das previsões do Departamento de Agricultura dos Estados Unidos (USDA) (88% contra menos de 35%). Mais relevante para o presente trabalho, a análise de importância das variáveis identificou a distância entre países, o PIB e a população como os fatores de maior influência nas previsões que reforça a escolha dessas dimensões como base do modelo gravitacional adotado nesta pesquisa.

Calheiros-Lobo, Au-Yong-Oliveira e Ferreira (2025) abordam a seleção de mercados estrangeiros para pequenas e médias empresas, propondo uma plataforma de aprendizado profundo generativo denominada DEEPEIA. O objetivo é recomendar o mercado de exportação mais adequado a cada produto ou serviço e identificar o parceiro ideal no país de destino, denominado pelos autores de *Foreign Champion*. A proposta é fundamentada em uma revisão sistemática da literatura, conduzida segundo as diretrizes PRISMA (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*), e complementada por entrevistas com especialistas, das quais resultou um conjunto de 184 variáveis utilizadas pelo sistema.

A arquitetura proposta integra diferentes fontes de dados, incluindo estatísticas de comércio internacional, indicadores macroeconômicos, dados de redes sociais e de plataformas de negócios. Para gerar as recomendações, a solução combina técnicas de aprendizado profundo, seleção de atributos e mecanismos de interpretabilidade, de modo a produzir sugestões explicáveis ao usuário.

O artigo não apresenta resultados quantitativos experimentais, pois a plataforma permanece em fase de conceitualização, e sua principal contribuição é a proposta de uma arquitetura integrada para apoio à internacionalização de empresas (CALHEIROS-LOBO; AU-YONG-OLIVEIRA; FERREIRA, 2025). Ainda assim, é

um dos trabalhos mais próximos do objetivo desta pesquisa, por tratar a seleção de mercados de exportação como um problema de recomendação apoiado em múltiplas fontes de dados e por valorizar a explicabilidade das sugestões, característica também desejável no sistema proposto.

Tiits et al. (2024) abordam a identificação de oportunidades de exportação ao nível de produto, com foco em apoiar a diversificação das exportações de economias de pequeno e médio porte. A proposta enriquece o modelo gravitacional tradicional com duas métricas de complexidade econômica: o Índice de Complexidade do Produto (*Product Complexity Index*, PCI), que mede a sofisticação de cada produto, e a densidade de relacionamento, que indica a proximidade de um produto em relação à estrutura produtiva do país. Diferentemente da prática usual, que se apoia em dados anuais agregados, o estudo utiliza a série mensal do UN Comtrade, referente ao período de 2016 a 2021, complementada pelo CEPII Gravity Dataset, com indicadores como PIB, PIB per capita, população e distância entre os países.

Metodologicamente, os autores estimam o modelo gravitacional por meio de algoritmos de aprendizado de máquina baseados em árvores, em especial a floresta aleatória (*random forest*), capazes de prever o valor do comércio bilateral em mais de cinco mil grupos de produtos definidos pelos seis dígitos do Sistema Harmonizado (SH). O modelo é treinado com os dados de 2016 a 2020 e testado nos dados inéditos de 2021, e seu desempenho é avaliado pelas métricas de MAE, MSE e  $R^2$ . A análise de importância das variáveis é empregada para interpretar quais fatores mais influenciam as previsões.

Os resultados mostram que um modelo relativamente simples, baseado no código do produto, no PIB, na distância e no mês, já alcança bom desempenho, com  $R^2$  em torno de 0,81. Acrescentar as métricas de complexidade e de densidade de relacionamento melhora pouco a precisão. Para este trabalho, o ponto mais útil é a conclusão dos autores de que a demanda prevista, por si só, não garante uma estratégia de exportação viável. Outros fatores além do tamanho das economias e da distância também pesam na viabilidade das operações, como barreiras comerciais, crescimento da demanda e risco do mercado de destino (TIITS et al., 2024). O sistema proposto aqui considera esses mesmos fatores, ao reunir o modelo gravitacional, a filtragem colaborativa, a filtragem por conteúdo, a sazonalidade e o risco-país. Os autores também analisam o caso do Brasil e identificam produtos com potencial de diversificação.

Liao et al. (2019) investigam a aplicação de algoritmos de recomendação ao comércio internacional, modelando-o como uma rede bipartida em que os países funcionam como usuários e os produtos como itens. A partir de dados de comércio

harmonizados (base BACI/CEPII) de 192 países e 786 produtos, referentes ao período de 2001 a 2015, os autores avaliam estratégias de recomendação voltadas à identificação de novos produtos com potencial de exportação para cada país.

O trabalho compara cinco algoritmos de recomendação baseados em propagação de informação na rede, entre eles o ProbS, o HeatS e o TProbS, avaliados por meio de previsões de cinco anos com as métricas de Precisão e *Recall*. A proposta é verificar quais métodos melhor antecipam as exportações futuras de cada país a partir da estrutura de coexportação observada entre os produtos.

Os resultados indicaram que o TProbS obteve a melhor acurácia de recomendação, enquanto o HeatS foi o mais eficaz em elevar a competitividade (*fitness*) dos países; as simulações mostraram que a maioria dos países analisados melhoraria sua competitividade ao seguir as recomendações (LIAO et al., 2019). É o trabalho mais próximo do presente em termos de técnica, por aplicar algoritmos de sistemas de recomendação diretamente sobre dados de comércio, ainda que sem o foco em um exportador específico e em fatores operacionais, lacuna que esta pesquisa busca preencher.

A Tabela 4.1 apresenta uma síntese comparativa dos trabalhos discutidos neste capítulo, destacando os modelos utilizados, as bases de dados, o foco do problema e as métricas de avaliação adotadas em cada estudo.

Tabela 4.1 – Comparação das principais características dos trabalhos relacionados

| Trabalho                                           | Modelo                                                                  | Base de Dados                                      | Foco                                                                      | Métricas                                            |
|----------------------------------------------------|-------------------------------------------------------------------------|----------------------------------------------------|---------------------------------------------------------------------------|-----------------------------------------------------|
| Rincon-Yanez et al. (2023)                         | <i>Knowledge Graph</i> + TransE + Árvore de Decisão                     | UN Comtrade, BACI/CEPII, CEPII Gravity             | Previsão de volume e de <i>links</i> comerciais                           | $R^2$ , MAE, Acurácia                               |
| Batarseh, Ghassem-Aghaee e Chong (2019)            | Regressão Linear, K-Means, ARIMA, XGBoost, LightGBM                     | USDA/GATS, WITS, U.S. ITC                          | Previsão de tendências de <i>commodities</i> agrícolas                    | $R^2$ (acurácia de previsão)                        |
| Calheiros-Lobo, Au-Yong-Oliveira e Ferreira (2025) | LSTM + <i>Transformer</i> + BORUTA + SHAP                               | UN Comtrade, WITS, World Bank, Twitter/X, LinkedIn | Seleção de mercado e identificação de parceiro                            | Proposta conceitual                                 |
| Tiits et al. (2024)                                | Modelo gravitacional + <i>random forest</i> (PCI e <i>relatedness</i> ) | UN Comtrade (mensal), CEPII Gravity                | Identificação de oportunidades de exportação por produto e destino        | MAE, MSE, $R^2$                                     |
| Liao et al. (2019)                                 | ProbS, HeatS, DI, TProbS                                                | BACI/CEPII (2001–2015)                             | Recomendação de produtos para exportação e complexidade econômica         | Precisão, <i>Recall</i>                             |
| Este trabalho                                      | Híbrido (gravitacional + filtragem colaborativa + conteúdo)             | ComexStat e dados da empresa, World Bank, PNUD     | Recomendação de mercados lusófonos africanos para exportação de alimentos | <i>Score</i> gravitacional, Precisão, <i>Recall</i> |

A partir da análise comparativa apresentada na Tabela 4.1, observa-se que os trabalhos selecionados utilizam abordagens distintas para o problema de intelligen-

cia comercial aplicada ao comércio internacional. Rincon-Yanez et al. (2023), Batarseh, Ghassem-Aghaee e Chong (2019) e Tiits et al. (2024) concentram-se na previsão de fluxos comerciais com técnicas de aprendizado de máquina, enquanto Liao et al. (2019) aplica algoritmos de sistemas de recomendação diretamente sobre redes de comércio. Calheiros-Lobo, Au-Yong-Oliveira e Ferreira (2025), por sua vez, propõe a abordagem mais abrangente em termos de variáveis e arquitetura, embora sem validação experimental. Em relação às bases de dados, a maioria dos trabalhos internacionais utiliza o UN Comtrade ou o BACI/CEPII, enquanto o presente trabalho se distingue por utilizar o ComexStat (base de dados oficial do comércio exterior brasileiro), combinado com informações internas da empresa-alvo, configurando uma abordagem ainda pouco explorada na literatura nacional.

Apesar dos avanços identificados, os trabalhos analisados apresentam limitações relevantes. A maioria baseia-se em dados do UN Comtrade, que nem sempre refletem com precisão os volumes efetivamente comercializados, uma vez que as declarações de importação e exportação entre países podem apresentar inconsistências (RINCON-YANEZ et al., 2023). Além disso, embora alguns trabalhos apontem essa necessidade como direção futura, nenhum incorpora ao modelo fatores operacionais, como a disponibilidade do fornecedor em determinado período, a sazonalidade da demanda no mercado de destino ou a compatibilidade entre o momento de oferta do exportador e o ciclo de compras do importador.

No âmbito institucional, a ApexBrasil oferece ferramentas gratuitas de inteligência comercial. Entre elas, destaca-se o Mapa de Oportunidades (ApexBrasil, 2025). A plataforma cruza a competitividade do Brasil com a demanda internacional e cobre cerca de 175 países. A partir do código NCM de um produto, o usuário descobre quais mercados já o importam, quanto importam e quem são os principais concorrentes. Os dados de exportação vêm do ComexStat, e os de demanda, de bases de comércio global.

De modo geral, Nenhum dos estudos identificados propõe um sistema de recomendação voltado especificamente para apoiar empresas brasileiras na seleção de mercados para os produtos de seu portfólio, cruzando os dados do ComexStat com indicadores macroeconômicos. É justamente essa lacuna que o presente trabalho busca preencher: a solução proposta combina o histórico de exportações brasileiro com indicadores como o PIB, a população e o IDH para fornecer à empresa-alvo recomendações de mercados potenciais no bloco PALOP, apoiando sua estratégia de expansão internacional para além dos destinos já atendidos.

## 5. METODOLOGIA

A metodologia deste trabalho descreve os procedimentos adotados para o desenvolvimento de um sistema de recomendação de mercados de exportação para uma empresa do setor alimentício do Oeste de Santa Catarina. O estudo classifica-se como pesquisa aplicada, quantitativa e exploratória, configurando-se como um estudo de caso (PRODANOV; FREITAS, 2013).

Após a definição do tema, foi realizada uma análise preliminar sobre a disponibilidade e a granularidade dos dados do ComexStat (Ministério do Desenvolvimento, Indústria, Comércio e Serviços, 2024), verificando a frequência de atualização dos registros públicos de exportação. Complementarmente, foram examinadas as ferramentas da ApexBrasil (ApexBrasil, 2025) para compreender como os dados de comércio exterior são tratados e disponibilizados para as empresas brasileiras.

Em seguida, foi realizada uma busca exploratória na literatura científica utilizando os termos *"recommender system"* AND *"export"* na base Google Scholar. A busca inicial em língua portuguesa retornou poucos resultados alinhados ao tema, sendo expandida para a literatura internacional, onde foram identificados estudos diretamente relacionados ao problema proposto.

O trabalho se divide em cinco etapas, detalhadas nas seções seguintes: coleta de dados, pré-processamento, aplicação do modelo gravitacional, construção do sistema de recomendação híbrido e avaliação dos resultados por meio das métricas de Precisão, Recall e F1-Score.

### 5.1 Coleta de Dados

A coleta dos dados será estruturada a partir de três fontes principais. Os dados de exportação serão obtidos da plataforma ComexStat (Ministério do Desenvolvimento, Indústria, Comércio e Serviços, 2024) no formato CSV. O processo de coleta será iniciado pela análise do portfólio de produtos da empresa-alvo, identificando o nome de cada produto e seu respectivo código Nomenclatura Comum do Mercosul (NCM). Esses códigos constituem a lista de filtro das consultas.

Cabe ressaltar que o ComexStat disponibiliza dados **agregados**: o NCM de oito dígitos é o maior nível de detalhamento de produto e os registros não identificam empresas individualmente, em razão do sigilo fiscal. Dessa forma, os volumes extraídos correspondem às exportações brasileiras por NCM, estado de origem (UF)

e país de destino. Com os códigos NCM será realizada uma consulta na plataforma ComexStat filtrando as exportações brasileiras por esses códigos, abrangendo todos os estados e o período de 2014 a 2024, com os países de destino restritos ao bloco Países Africanos de Língua Oficial Portuguesa (PALOP): Angola, Moçambique, Cabo Verde, Guiné-Bissau e São Tomé e Príncipe.

Os indicadores macroeconômicos e de desenvolvimento humano dos países do PALOP serão coletados de duas fontes complementares. O Produto Interno Bruto (PIB), a população total e a taxa de alfabetização de adultos (indicador SE.ADT.LITR.ZS) serão obtidos da base do Banco Mundial (World Bank, 2024a) por meio da biblioteca *wbgapi*; o Índice de Desenvolvimento Humano (IDH) será coletado do Relatório de Desenvolvimento Humano do PNUD (PNUD, 2025), em formato CSV. Em ambos os casos, será considerado o ano mais recente disponível para cada país.

Os dados internos da empresa-alvo serão fornecidos diretamente pela organização e tratados de forma confidencial, sem divulgação de informações que permitam a identificação da empresa.

A sazonalidade será tratada em duas dimensões. A sazonalidade do **país de destino** é determinada de forma geográfica, a partir do hemisfério e do mês do ano; nos países situados na faixa equatorial, considera-se o regime de estação seca e chuvosa em vez do ciclo verão/inverno. A sazonalidade do **produto** é derivada da distribuição mensal de suas exportações na própria base do ComexStat, identificando os meses de maior demanda de cada NCM. Combinando as duas dimensões, o sistema identificará quais produtos do portfólio são mais adequados para recomendação em função da estação no país de destino.

## 5.2 Pré-processamento dos Dados

Após a coleta, os dados das três fontes serão integrados e submetidos a um processo de pré-processamento com o objetivo de garantir a qualidade e a consistência das informações utilizadas pelo sistema de recomendação.

A Figura 5.1 apresenta o pipeline completo do sistema, desde a coleta dos dados até a geração do ranking final de pares produto–mercado recomendados.




Figura 5.1 – Pipeline do sistema de recomendação proposto.

As etapas de pré-processamento previstas são:

- **Filtragem por país de destino:** seleção apenas dos registros do ComexStat cujo país de destino pertence ao bloco PALOP;
- **Filtragem por código NCM:** seleção apenas dos registros correspondentes aos códigos NCM do portfólio da empresa-alvo;
- **Tratamento de valores ausentes:** remoção de registros com informações incompletas nas variáveis utilizadas pelo modelo;
- **Normalização:** padronização das variáveis numéricas e dos scores calculados pelo modelo no intervalo  $[0, 1]$ , garantindo comparabilidade entre os diferentes componentes;
- **Integração das fontes:** junção dos dados do ComexStat com os indicadores macroeconômicos do Banco Mundial e do PNUD e com a lista de NCMs do portfólio da empresa-alvo, formando uma matriz unificada de produto  $\times$  estado  $\times$  país  $\times$  mês que alimentará o modelo.

### 5.3 Modelo Gravitacional

Conforme apresentado na Seção 2.5, o modelo gravitacional de comércio internacional, originalmente proposto por Tinbergen (1962), estima o potencial de fluxos

comerciais entre dois países com base em suas massas econômicas e na distância geográfica entre eles. A formulação clássica do modelo é expressa pela Equação 5.1:

$$F_{ij} = G \times \frac{M_i \times M_j}{D_{ij}^2} \quad (5.1)$$

onde  $F_{ij}$  representa o fluxo comercial estimado entre o país exportador  $i$  e o país importador  $j$ ;  $M_i$  e  $M_j$  são as massas econômicas dos países, representadas pelo PIB;  $D_{ij}$  é a distância geográfica entre os dois países; e  $G$  é uma constante de proporcionalidade (TINBERGEN, 1962).

Neste trabalho, o modelo gravitacional é adaptado para calcular um score de potencial de mercado para cada país do PALOP, incorporando a população como variável adicional. A inclusão da população justifica-se pelo fato de que mercados mais populosos tendem a apresentar maior capacidade de absorção de produtos alimentícios industrializados (BATARSEH; GHASSEM-AGHAEI; CHONG, 2019). Como o PIB e a população são atributos do país, e não do produto, este score permanece definido por país, conforme a Equação 5.2:

$$S_j = \alpha \times \frac{PIB_j \times POP_j}{D_{Bj}^2} \quad (5.2)$$

onde  $S_j$  representa o score de potencial do mercado  $j$ ;  $PIB_j$  é o Produto Interno Bruto do país  $j$ ;  $POP_j$  é a população do país  $j$ ;  $D_{Bj}$  é a distância geográfica entre o Porto de Itajaí e o porto principal do país  $j$ ; e  $\alpha$  é uma constante de normalização (TINBERGEN, 1962; RINCON-YANEZ et al., 2023).

Como o valor de  $S_j$  possui escala arbitrária, ele é normalizado no intervalo  $[0, 1]$  pela técnica *min-max*, conforme a Equação 5.3:

$$\hat{S}_j = \frac{S_j - \min_k S_k}{\max_k S_k - \min_k S_k} \quad (5.3)$$

Ressalta-se que, neste trabalho, o modelo gravitacional é utilizado como uma **ferramenta de pontuação** do potencial de mercado, ou seja, a fórmula é aplicada diretamente para calcular um score comparativo entre os países do PALOP, sem ajuste estatístico. Essa abordagem é adequada dado o número reduzido de países analisados.

A distância geográfica será calculada com base nas coordenadas geográficas do Porto de Itajaí, principal porto exportador do estado de Santa Catarina, e do porto principal de cada país de destino, utilizando a fórmula de Haversine. A Tabela 5.1 apresenta as distâncias geodésicas calculadas. Observa-se que Cabo Verde é o país

mais próximo (5.384 km) e Moçambique o mais distante (7.931 km), o que impacta diretamente no score gravitacional de cada mercado.

Tabela 5.1 – Distância geodésica entre o Porto de Itajaí e os portos dos países do PALOP

| País                | Porto de destino  | Distância (km) |
|---------------------|-------------------|----------------|
| Angola              | Porto de Luanda   | 6.786          |
| Moçambique          | Porto de Maputo   | 7.931          |
| Cabo Verde          | Porto da Praia    | 5.384          |
| Guiné-Bissau        | Porto de Bissau   | 5.597          |
| São Tomé e Príncipe | Porto de São Tomé | 6.643          |

Fonte: Baseado na fórmula de Haversine.

#### 5.4 Sistema de Recomendação Utilizado

O sistema de recomendação pretende-se híbrido, combinando três componentes complementares: o modelo gravitacional (Seção 5.3), a filtragem colaborativa e a filtragem baseada em conteúdo (ADOMAVICIUS; TUZHILIN, 2005). O sistema produz recomendações no nível do par produto–país, ou seja, do par formado por cada código NCM do portfólio da empresa-alvo e cada país do PALOP: para cada produto do portfólio, gera-se um ranking dos países do PALOP segundo o score final de recomendação, definido na Equação 5.6. Cada componente gera um score parcial para cada par produto–país e, a partir da combinação ponderada desses scores, ajustada pela sazonalidade e pelo risco-país, o sistema produz a recomendação final dos mercados do PALOP com maior potencial para o portfólio da empresa-alvo.

Na etapa de filtragem colaborativa, pretende-se utilizar o algoritmo KNN (*K-Nearest Neighbors*), por meio da biblioteca *scikit-learn* (PEDREGOSA et al., 2011), para identificar estados brasileiros com padrões de exportação semelhantes aos dos produtos do portfólio da empresa estudada. Para isso, serão considerados os registros de exportação obtidos no ComexStat, filtrados pelos códigos NCM correspondentes aos produtos da empresa, bem como informações relacionadas ao valor FOB (*Free on Board*), período da exportação, estado exportador e país de destino pertencente ao bloco PALOP. A busca abrange todos os estados brasileiros, incluindo Santa Catarina, onde a empresa-alvo está localizada e onde outras empresas do mesmo setor também atuam.

Cada estado será representado por um conjunto de características derivadas de seu histórico de exportações. O algoritmo KNN calculará a similaridade entre o

portfólio da empresa-alvo e o perfil exportador de cada estado, identificando aqueles com comportamento mais próximo ao da empresa. Os estados mais semelhantes serão utilizados como fonte de conhecimento para estimar o potencial de exportação dos produtos da empresa para os países do PALOP. Parte-se do pressuposto de que mercados que já importam produtos equivalentes exportados por outros estados brasileiros podem representar oportunidades potenciais para empresas que atuam no mesmo segmento produtivo. O score colaborativo para cada par produto–país é calculado conforme a Equação 5.4:

$$SC_{ij} = \frac{\sum_{s \in E} \text{sim}(c, s) FOB_{s,i,j}}{\sum_{s \in E} \text{sim}(c, s)} \quad (5.4)$$

onde  $c$  é o perfil exportador da empresa-alvo, representado pelo conjunto de NCMs de seu portfólio;  $E$  é o conjunto dos  $K$  estados identificados pelo KNN;  $\text{sim}(c, s)$  é a similaridade entre a empresa-alvo e o estado  $s$ ; e  $FOB_{s,i,j}$  é o volume FOB exportado pelo estado  $s$  do produto  $i$  para o país  $j$  do PALOP.

A filtragem baseada em conteúdo avalia a adequação de cada país do PALOP como destino para produtos alimentícios, utilizando o IDH e a taxa de alfabetização como indicadores complementares ao PIB e à população já contemplados no modelo gravitacional. O score de conteúdo é calculado conforme a Equação 5.5:

$$SBC_j = \gamma_1 \widehat{IDH}_j + \gamma_2 \widehat{ALF}_j, \quad \gamma_1 + \gamma_2 = 1 \quad (5.5)$$

onde  $\widehat{IDH}_j$  e  $\widehat{ALF}_j$  são o IDH e a taxa de alfabetização do país  $j$  normalizados, e  $\gamma_1$  e  $\gamma_2$  são os pesos atribuídos a cada atributo.

A sazonalidade é incorporada como fator de ajuste no nível do par produto–país. A sazonalidade do destino é determinada geograficamente, a partir do hemisfério e do mês (nos países da faixa equatorial, considera-se o regime de estação seca e chuvosa em vez do ciclo verão/inverno), enquanto a sazonalidade do produto é derivada da distribuição mensal de suas exportações na base do ComexStat. Produtos com maior demanda na estação vigente no país de destino recebem fator de ajuste mais alto.

A decisão exportadora não depende exclusivamente do potencial de demanda: fatores como estabilidade política e ambiente institucional influenciam a viabilidade das operações (ROOT, 1994). Por isso, pretende-se incorporar ao score final um fator de ajuste de risco-país ( $\rho_j$ ), obtido a partir do indicador de estabilidade política dos *Worldwide Governance Indicators* (WGI) do Banco Mundial (World Bank, 2024b), nor-

malizado no intervalo  $[0, 1]$ . Como a instabilidade decorre de eventos abruptos, não previsíveis por séries históricas,  $\rho_j$  não é um componente preditivo: funciona como fator de prudência que modera o potencial estimado no momento da recomendação, penalizando os mercados de maior instabilidade.

O score final de recomendação combina os três componentes (gravitacional, colaborativo e de conteúdo), ajustado pela sazonalidade e pelo risco do mercado de destino, conforme a Equação 5.6:

$$SF_{ij}^{(t)} = \rho_j \cdot \beta_{ij}^{(t)} \left( w_1 \hat{S}_j + w_2 \widehat{SC}_{ij} + w_3 \widehat{SBC}_j \right), \quad w_1 + w_2 + w_3 = 1 \quad (5.6)$$

onde  $\hat{S}_j$  é o score gravitacional normalizado do país  $j$ ;  $\widehat{SC}_{ij}$  e  $\widehat{SBC}_j$  são os scores colaborativo e de conteúdo normalizados;  $\rho_j$  é o fator de risco-país;  $\beta_{ij}^{(t)}$  é o fator de ajuste sazonal; e  $w_1$ ,  $w_2$  e  $w_3$  são os pesos de cada componente, com soma unitária, a serem definidos durante a implementação.

## 5.5 Ferramentas, Tecnologias e Métricas Utilizadas

O desenvolvimento das etapas previstas nesta pesquisa será realizado utilizando um conjunto de ferramentas e bibliotecas amplamente empregados em estudos de ciência de dados e sistemas de recomendação:

- **Coleta de dados:** Extração dos registros de exportação por meio da plataforma ComexStat (Ministério do Desenvolvimento, Indústria, Comércio e Serviços, 2024) no formato CSV; dos indicadores macroeconômicos via base de dados do Banco Mundial utilizando a biblioteca *wbgapi* (World Bank, 2024a); e do IDH a partir do arquivo CSV disponibilizado pelo PNUD (PNUD, 2025).
- **Ambiente de processamento:** Execução e organização das etapas em Python, utilizando Google Colaboratory (Google Colab) como ambiente de desenvolvimento.
- **Manipulação de dados:** Uso das bibliotecas *Pandas* e *NumPy* para leitura, filtragem, limpeza e agregação dos dados extraídos do ComexStat, do Banco Mundial e do PNUD.
- **Armazenamento:** Estruturação dos dados em arquivos CSV, garantindo compatibilidade e reprodutibilidade entre as etapas do pipeline.

- **Sistema de recomendação:** A filtragem colaborativa será implementada com a biblioteca *scikit-learn* (PEDREGOSA et al., 2011), utilizando o algoritmo KNN para identificar os estados vizinhos; a combinação ponderada dos scores (Equação 5.4) é então calculada em Python com a biblioteca *NumPy*. Os demais componentes do sistema híbrido (modelo gravitacional, filtragem por conteúdo e combinação final dos scores) também são implementados em Python com a biblioteca *NumPy*.
- **Modelo gravitacional:** Cálculo do score gravitacional e das distâncias geodésicas entre o Porto de Itajaí e os portos dos países do PALOP utilizando a fórmula de Haversine, implementada em Python com a biblioteca *NumPy*.
- **Visualização:** Construção de gráficos e do ranking final de pares produto–mercado recomendados com as bibliotecas *Matplotlib* e *Seaborn*.
- **Métricas de avaliação:** A qualidade das recomendações geradas será mensurada pelas métricas de Precisão, Recall e F1, conforme definidas na Seção 3.4. Adicionalmente, será calculado o score gravitacional médio dos mercados recomendados como medida complementar do potencial econômico dos destinos sugeridos. O protocolo de avaliação detalhado é apresentado na Seção 5.6.

## 5.6 Protocolo de Avaliação

A avaliação do sistema de recomendação proposto adota um protocolo de validação temporal adequado a domínios em que os dados possuem ordenação cronológica, como é o caso das séries históricas de exportação. Nesse protocolo, o sistema é construído a partir de um período de treino e avaliado quanto à sua capacidade de prever observações de um período de teste posterior, não utilizado em nenhuma etapa de construção do modelo.

A base do ComexStat, abrangendo o período de 2014 a 2024, é dividida em dois subconjuntos temporais. O subconjunto de treino, composto pelos registros de 2014 a 2021, alimentará os três componentes do sistema híbrido o modelo gravitacional, a filtragem colaborativa e a filtragem baseada em conteúdo. O subconjunto de teste, formado pelos registros de 2022 a 2024, será reservado para a avaliação e servirá como referência para verificar a qualidade das recomendações geradas.

## 6. CRONOGRAMA

A Tabela 6.1 apresenta o cronograma das atividades previstas para o desenvolvimento do TCC I e do TCC II.

| Tarefas                                           | Mar/26 | Abr/26 | Mai/26 | Jun/26 | Jul/26 | Ago/26 | Set/26 | Out/26 | Nov/26 | Dez/26 |
|---------------------------------------------------|--------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| Definição do tema                                 | X      |        |        |        |        |        |        |        |        |        |
| Pesquisa teórica inicial                          | X      | X      |        |        |        |        |        |        |        |        |
| Busca e seleção de artigos                        |        | X      |        |        |        |        |        |        |        |        |
| Escrita do TCC I                                  |        |        | X      | X      |        |        |        |        |        |        |
| Defesa do TCC I                                   |        |        |        |        | X      |        |        |        |        |        |
| Coleta dos dados (ComexStat, Banco Mundial, PNUD) |        |        |        |        |        | X      | X      |        |        |        |
| Pré-processamento e integração das bases          |        |        |        |        |        |        | X      | X      |        |        |
| Implementação do modelo gravitacional             |        |        |        |        |        |        |        | X      |        |        |
| Implementação do sistema de recomendação          |        |        |        |        |        |        |        | X      | X      |        |
| Avaliação (validação temporal e métricas)         |        |        |        |        |        |        |        |        | X      | X      |
| Interpretação dos resultados                      |        |        |        |        |        |        |        |        |        | X      |
| Escrita do TCC II                                 |        |        |        |        |        |        |        |        | X      | X      |
| Defesa do TCC II                                  |        |        |        |        |        |        |        |        |        | X      |

Tabela 6.1 – Cronograma de atividades para o desenvolvimento do TCC I e TCC II.

## REFERÊNCIAS BIBLIOGRÁFICAS

- ADOMAVICIUS, G.; TUZHILIN, A. Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engineering*, v. 17, n. 6, p. 734–749, 2005.
- ApexBrasil. *Painel de Inteligência Comercial*. Brasília, 2025. Disponível em: <<https://apexbrasil.com.br/content/apexbrasil/br/pt/solucoes/inteligencia/painel-de-inteligencia-comercial.html>>.
- BATARSEH, F. A.; GHASSEM-AGHAEI, N.; CHONG, A. E. Application of machine learning in forecasting international trade trends. In: *2019 IEEE International IOT, Electronics and Mechatronics Conference (IEMTRONICS)*. [S.l.]: IEEE, 2019. p. 1–7.
- CALHEIROS-LOBO, R.; AU-YONG-OLIVEIRA, M.; FERREIRA, J. V. Deep learning: Conceptualizing a generative deep learning foreign market recommender for smes. *Information*, v. 16, n. 8, p. 636, 2025.
- CAVUSGIL, S. T. Guidelines for export market research. *Business Horizons*, v. 28, n. 6, p. 27–33, 1985.
- Comunidade dos Países de Língua Portuguesa. *Estratégia de Facilitação do Comércio da CPLP*. Lisboa, 2022. Disponível em: <<https://www.cplp.org>>.
- DUNNING, J. H. Toward an eclectic theory of international production: Some empirical tests. *Journal of International Business Studies*, v. 11, p. 9–31, 1980.
- HOLLENSSEN, S. *Global Marketing*. 8. ed. Harlow: Pearson, 2020.
- JOHANSON, J.; VAHLNE, J.-E. The internationalization process of the firm: A model of knowledge development and increasing foreign market commitments. *Journal of International Business Studies*, v. 8, n. 1, p. 23–32, 1977.
- KALDOR, N. *Causes of the Slow Rate of Economic Growth of the United Kingdom*. Cambridge: Cambridge University Press, 1966.
- LIAO, H. et al. *Enhancing countries' fitness with recommender systems on the international trade network*. 2019.
- MINERVINI, N. *Engenharia de exportação: rotas para mercados internacionais*. 6. ed. São Paulo: Saraiva, 2021.
- Ministério do Desenvolvimento, Indústria, Comércio e Serviços. *Manual de Estatísticas de Comércio Exterior*. Brasília, 2024. Disponível em: <<http://comexstat.mdic.gov.br>>.
- MOTTA, C. L. R. d. et al. Sistemas de recomendação. In: PIMENTEL, M.; FUKS, H. (Ed.). *Sistemas Colaborativos*. [S.l.]: Elsevier, 2011. cap. 15.
- PEDREGOSA, F. et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.

PNUD. *Relatório de Desenvolvimento Humano 2025*. Nova York, 2025. Disponível em: <<https://hdr.undp.org>>.

Prado Júnior, C. *Formação do Brasil Contemporâneo: Colônia*. 1ª edição digital. ed. São Paulo: Companhia das Letras, 2011. Originalmente publicado em 1942.

PRODANOV, C. C.; FREITAS, E. C. d. *Metodologia do trabalho científico: métodos e técnicas da pesquisa e do trabalho acadêmico*. 2. ed. Novo Hamburgo: Feevale, 2013. Disponível em: <<https://www.feevale.br/institucional/editora-feevale/metodologia-do-trabalho-cientifico>>.

RESNICK, P. et al. Grouplens: An open architecture for collaborative filtering of netnews. In: *Proceedings of the ACM Conference on Computer Supported Cooperative Work*. Chapel Hill, NC: [s.n.], 1994. p. 175–186.

RINCON-YANEZ, D. et al. Accurate prediction of international trade flows: Leveraging knowledge graphs and their embeddings. *Journal of King Saud University – Computer and Information Sciences*, v. 35, n. 10, p. 101789, 2023.

ROOT, F. R. *Entry Strategies for International Markets*. New York: Lexington Books, 1994.

SHARDANAND, U.; MAES, P. Social information filtering: Algorithms for automating word of mouth. In: *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*. [S.I.]: ACM Press, 1995. p. 210–217.

THIRLWALL, A. P. The balance of payments constraint as an explanation of international growth rate differences. *Banca Nazionale del Lavoro Quarterly Review*, v. 32, n. 128, p. 45–53, 1979.

TIITS, M. et al. Relatedness and product complexity meet gravity models of international trade. *Journal of Open Innovation: Technology, Market, and Complexity*, v. 10, n. 2, p. 100288, 2024.

TINBERGEN, J. *Shaping the World Economy: Suggestions for an International Economic Policy*. New York: Twentieth Century Fund, 1962.

World Bank. *World Development Indicators*. Washington, DC, 2024. Disponível em: <<https://data.worldbank.org>>.

World Bank. *Worldwide Governance Indicators*. Washington, DC, 2024. Disponível em: <<https://www.worldbank.org/en/publication/worldwide-governance-indicators>>.